

© Květuše Sýkorová	OLAP a DataMining	
	Základní pojmy	

© Květuše Sýkorová	Údaje x Informace x Poznatky	
	• Informační technologie – shromažďování údajů => Big Data • Transformace – 1. údaje • 00110110 10110100 ... – 2. informace • konkrétní množina záznamů – 3. poznatky • využívají se pro rozhodování	
	BI = Business Intelligence = transformace údajů na poznatky	

24.03.2025

2

Big Data – Jak jsou velká?

název	velikost
B = Bajt	8 b
KB = Kilobajt	2 ¹⁰ B
MB = Megabajt	2 ²⁰ B
GB = Gigabajt	2 ³⁰ B
TB = Terabajt	2 ⁴⁰ B
PB = Petabajt	2 ⁵⁰ B
EB = Exabajt	2 ⁶⁰ B
ZB = Zettabajt	2 ⁷⁰ B
YB = Yottabajt	2 ⁸⁰ B

- FB
 - 2012 (40 miliard fotografií = 9,3PB)
 - 2024 (260 miliard foto = >20PB)
 - 60 TB / týden
- Obchodní analytici
 - velké datové sady
 - BI = business intelligence
 - analytické systémy
 - OLAP = Online Analytical Processing
 - databáze
 - DWH (Data Warehouse)
 - DL (Data Lake)
 - DLH (Data Lakehouse)

24.03.2025

3

© Květuše Sýkorová

OLAP x OLTP

- technologie uložení dat v databázi
 - OLTP = Online Transaction Processing
 - umožňuje snadno a bezpečně ukládat změny ve víceuživatelském (konkurenčním) prostředí
 - data jsou neustále modifikována více uživateli – data vždy aktuální
 - nad daty jsou prováděny jednorázové dotazy – SQL
 - OLAP = Online Analytical Processing
 - umožňuje uspořádat velké objemy dat pro následnou analýzu obchodních trendů a výsledků – tzv. BI=Business Intelligence
 - data jsou pravidelně nahrávána jednorázově v dávkách (denně, týdně)
 - nemění se, pouze přibývají
 - nad daty jsou prováděny složité dotazy

24.03.2025

4

© Květuše Sýkorová

OLTP x OLAP	
• pouze aktuální údaje – příklad: e-shop • objektově-relační návrh – minimalizace redundance • INSERT, UPDATE, DELETE – zdroj = uživatel db • 1 okamžik = přístup spousty uživatelů z celého světa – rychlá odezva OLTP	• časově závislá data – příklad: katastr nemovit. • návrh fakta – dimenze – vysoká redundance • čištění dat, načtení dat – zdroj: jiné DB, CSV, TXT, ... • periodické složité souhrny pro několik uživatelů z dané firmy – pomalá odezva OLAP
© Květuše Sýkorová	24.03.2025 5

Přehled DBMS	
• OLTP = Online Transaction Processing – oblast použití = neomezená • velké množství on-line transakcí pro velké množství klientů – bankovní, obchodní, ... – cíl = automatizace každodenních činností v podnikání • skladové hospodářství, mzdy, nákup a prodej, řízení a monitorování procesů v reálném čase – Velmi oblíbené ve firemní praxi • ERP = Enterprise Resource Planning – OLTP pokrývající většinu podnikových aktivit • mohou obsahovat i jednodušší analýzy	24.03.2025 6

© Květuše Sýkorová	Přehled DBMS	
	• MIS = Management Information Systems • systémy pro podporu řízení a rozhodování – oblast použití = operativně taktická úroveň firmy • poskytují kvalitní informace pro řídící pracovníky – cíl = podpora řízení a rozhodování • vstupem jsou údaje z OLTP • poskytují komplexní přehledy a sestavy agregované podle různých hledisek – časové, geografické, organizační, ... • původní systémy měly složitou organizaci – výsledky byly k dispozici po několika dnech, týdnech i měsících	7

24.03.2025

© Květuše Sýkorová	Přehled DBMS	
	• DSS = Decision Support Systems • systémy pro podporu rozhodování • často nadstavba MIS – oblast použití = takticko strategická úroveň firmy • poskytují kvalitní informace pro řídící pracovníky – cíl = podpora rozhodování • vstupem jsou údaje z OLTP a následně MIS • poskytují výsledky složitých analýz	8

24.03.2025

© Květuše Sýkorová	Přehled DBMS
	• EIS = Executive Information Systems • systémy pro podporu řízení • dnes často označovány BI – oblast použití = strategická úroveň firmy • poskytují kvalitní informace pro vrcholové řízení – cíl = podpora vrcholového řízení • vstupem jsou údaje z OLTP, MIS a DSS • často nahrazovány pouze DSS
	24.03.2025 9

© Květuše Sýkorová	systemy BI
	• BI = Business Intelligence – informační analytické systémy • analýza minulých a současných aktivit → předpovídání budoucích událostí • nepodporují provozní aktivity (zpracování objednávek) • usnadňují hodnocení, analýzu, plánování, řízení, rozhodování – vhodné jako podpora pro management – provozní systémy • zajišťují primární obchodní aktivity – systémy prodeje, nákupu, řízení skladových zásob, ... – průběžné záznamy obchodních aktivit • spolupráce s DBS – provozní databáze / transakční systémy / OLTP
	24.03.2025 10

© Květuše Sýkorová	systemy BI
	• zdroje dat systémů BI – data z provozních databází • načtení, zpracování • provozní data nemění !!! • POZOR: – zpomalují chod provozní db (velká zátěž pro DBMS) – údržba systému BI vyžaduje nástroje, které provozní systémy nemají – provozní data nejsou vyčištěná – data extrahovaná z provozních databází • spravují pouze extrahovanou databázi • jedná se o „výtah“ z provozních dat – data získaná od dodavatelů • zakoupení 24.03.2025 11

© Květuše Sýkorová	systemy BI
	• vykazovací systémy – filtrace, třídění, seskupování, jednoduché výpočty • SQL + extended SQL – souhrny aktuálního stavu – porovnání aktuálního stavu s minulým, s prognózou – klasifikace entit – klíčové sestavy • doručení uživatelům včas, vhodný formát (tisk, graf, web, ...) • dolování dat (data mining) – pokročilé matematické a statistické výpočty • citlivostní analýza, předpovědi, rozhodování – výsledky často součástí jiné sestavy 24.03.2025 12

© Květuše Sýkorová	Data Warehouse
	• DWH = datový sklad – velké množství strukturovaných dat • nutná transformace dat (proces ETL), poté nahrání do DWH • ACID transakce nad transformovanými daty (řezy) – optimalizované na dotazy • schéma STAR a SNOWFLAKE • rychlé analytické dotazy nad daty – podpora BI – finančně náročnější, málo flexibilní a škálovatelné • struktura DWH optimalizována na rychlé analytické dotazy • snadnější správa (přísnější kvalita dat i strukturovanost dat) – použití: • obchodní analýzy, reporty, apod. 24.03.2025 13

© Květuše Sýkorová	Data Lake
	• DL = datové jezero – velké množství (-/polo/ne) strukturovaných dat • tabulky, JSON, XML, texty, obrázky, videa, ... – optimalizovaná na ukládání – nízké náklady, flexibilní, škálovatelná • možný nárůst dat i výkonu, často cloudové řešení • data v původním formátu => není potřeba ETL • náročná a pokročilá správa dat (Data Swamp = datová bažina) – podpora analytických dotazů • analýza a zpracování pomocí strojového učení, atd. – použití: • uložení velkého objemu různorodých dat 24.03.2025 14

DL vs DWH

	Data Lake	Data Warehouse
Purpose	Big data storage and research	Big data analysis
Data Type	Unstructured, semi-structured & structured	Structured
Users	Data scientists and data engineers	Business analysts and data analysts
Cost	Low	High
Agility & Accessibility	High	Lower
Security	Lower	High

DATA WAREHOUSE	vs.	DATA LAKE
structured, processed	DATA	structured / semi-structured / unstructured, raw
schema-on-write	PROCESSING	schema-on-read
expensive for large data volumes	STORAGE	designed for low-cost storage
less agile, fixed configuration	AGILITY	highly agile, configure and reconfigure as needed
mature	SECURITY	maturing
business professionals	USERS	data scientists et. al.

DATA LAKE vs DATA WAREHOUSE


DATA WAREHOUSE vs DATA LAKE

© Květuš 24.03.2025

Data Lakehouse

- DLH = datové ???
 - kombinuje výhody DWH a DL
- jednotný systém pro správu dat
 - různě strukturovaná data z různých zdrojů na jednom místě
- podpora analytických dotazů
 - business intelligence (BI) + strojové učení (ML)
- nízké náklady
 - levné cloudové úložné služby
- ACID transakce
 - zajištění konzistence dat a řízení transakcí

© Květuše Sýkorová 24.03.2025 16



Data Warehouse

- DWH = Datový sklad
 - zvláštní typ relační databáze
 - DWH = DBS + data + programy obsluhy specializující se na BI
 - umožňuje řešit úlohy zaměřené převážně na analytické dotazování nad rozsáhlými soubory dat
- William Inmon:
 - Orientace na subjekt:
 - RDB – minimální redundance uložených dat + normalizace (3NF) + vnitřní provázání logických celků – relace
 - DWH – vnitřní separace jednotlivých funkčních bloků pro zvýšení čitelnosti pro uživatele, vedoucí k vyšším paměťovým nárokům

© Květuše Sýkorová


24.03.202

18

DWH - ETL	
© Květuše Sýkorová	• systémy ETL – Extract, Transform and Load • načte data z provozních db do db DWH – vyčistí a připraví data pro BI • dost složitý proces – „nečistá data“ – pohlaví zákazníka „P“, věk zákazníka „236“, barva „červená“, ... – chybějící hodnoty (null) – nekonzistentní data (změna telefonu zákazníka) – nesprávný formát (datum, čas) – neintegrována data (z více zdrojů) – redundantní data (nadbytečné atributy) • datová transformace – CR na Česká Republika, CA na Kanada, ...
24.03.2025	19

DWH x DM x EDW	
© Květuše Sýkorová	• DWH = Data Warehouse – datové sklady • příjem dat od distributora • vyčištění, zpracování, uložení • DM = Data Mart – datová tržiště • získání dat z DWH pouze pro určitou obchodní aktivitu – webové protokoly, skladová historie, maloobchodní prodej, ... • EDW = Enterprise DWH – architektura podnikového datového skladu • EDW = DWH + DM – provoz finančně náročný => mohou si to dovolit jen větší podniky
24.03.2025	20

DWH & DM



© Květuše Sýkorová


24.03.2025

https://en.wikipedia.org/wiki/Data_warehouse

21

databázový návrh DB DWH

- multidimensional database = databáze dimenzí
 - efektivní dotazování a analýza
 - používají se historická data
 - návrh musí podporovat časové změny dat
 - datová dimenze dat
 - časová dimenze dat




© Květuše Sýkorová

24.03.2025

dimensional database

- Star schema = hvězdicové schéma
 - tabulky faktů
 - plně normalizované
 - obsahují míry obchodní aktivity (kvantitativní, faktická data)
 - tabulky dimenzí
 - nemusí být normalizované
 - obsahuje hodnoty atributů, které popisují míry faktů

tabulka faktů funguje jako
spojovací tabulka v relaci M:N



© Květuše Sýkorová


24.03.2025

<http://www.1keydata.com/datawarehousing/star-schema.html>

23

dimensional database



- Snowflake schema = schéma sněhové vločky
 - tabulky faktů
 - plně normalizované
 - tabulky dimenzí
 - musí být normalizované do 3NF




© Květuše Sýkorová

24.03.2025

24





Zdroje

<http://olap.com/types-of-olap-systems/>
<https://mondrian.pentaho.com/documentation/olap.php>
http://etl-tools.info/en/pentaho-tutorial-L003_cube_designer.htm
<https://www.geeksforgeeks.org/difference-between-olap-and-oltp-in-dbms/>
<https://www.geeksforgeeks.org/olap-guidelines-codds-rule/>
<https://www.geeksforgeeks.org/difference-between-er-modeling-and-dimensional-modeling/>
<https://www.geeksforgeeks.org/dimensional-data-modeling/>

Zdroj pro OLAP, DW, DM, KDD a Data Mining
https://www.tutorialspoint.com/data_mining/index.htm

Vzorová data:
<https://www.kaggle.com/datasets>

Jazyk DMQL / GMQL / MSQL
<http://www.conceptual-modeling.org/products/gmql-dmql>
<http://www.cs.bme.hu/~marti/adatbanya/dmqlsyntax.html>
<https://www.flexmls.com/developers/rets/tutorials/dmql-tutorial/>

© Květuše Sýkorová

24.03.2025

28

© Květuše Sýkorová	Děkuji za pozornost	
	24.03.2025	29