

© Květuše Sýkorová	Datová úložiště
	Data mining

© Květuše Sýkorová	Dolování dat
	• Data mining – proces, kterým zjišťujeme vzory v datech • organizace tak získají relevantní informace pro obchodní potřeby – nezbytné pro BI – existuje mnoho technik DM • souhrny dat <-----> AI – etapa ETL • důležitá součást procesu dolování dat – čištění dat – transformace dat – agregace dat • nezbytné pro zajištění kvality dat a závěrů ostatních technik

07.04.2025

2

Data mining	
© Květuše Sýkorová	• Techniky dolování dat – Tracking patterns (sledování vzorů) • základní technika dolování dat • identifikace trendů a vzorců a jejich sledování – např. trendy prodeje pro určitou demografickou skupinu osob – Classification (klasifikace) • analýza atributů, které jsou spojeny s různými typy dat • hledají se základní charakteristiky dat -> klasifikují se kategorie souvisejících dat – např. pro odstranění souvisejících dat z dokumentů – Association (asociace, sdružování) • souvisí se statistikou a strojovým učením • výskyt určitých dat je spojen s výskytem jiných dat – např. nákup hamburgerů je často doprovázen i nákupem hranolků
	07.04.2025 3

Data mining	
© Květuše Sýkorová	• Techniky dolování dat – Outlier detection (detekce odlehlých hodnot) • vyhledávání anomálií v souborech dat • vede ke snadnějšímu pochopení proč k těmto anomáliím dochází – např. v určitou denní dobu enormní nárůst plateb kreditními kartami – Clustering (shlukování, shluková analýza) • opírá se o vizualizaci pro pochopení dat • využívají barevné grafové techniky pro zobrazení distribuce dat a identifikaci trendů – přímo vidí vztahy a trendy – Regression (regrese) • identifikují povahu vztahů mezi proměnnými v souboru dat • určují kauzální vztahy X korelační vztahy – jasně odhalují souvislosti jednotlivých proměnných
	07.04.2025 4

© Květuše Sýkorová	Data mining
	• Techniky dolování dat – Prediction (predikce, předpověď, prediktivní analýza) • využívá vzory nalezené v aktuálních nebo historických datech k jejich rozšíření do budoucnosti • určuje jaké trendy se budou v datech dít dál do budoucnosti – existuje více přístupů a algoritmů – Sequential patterns (sekvenční vzory) • odhalování řady událostí, které se odehrávají za sebou – např. jaké oblečení si zákazníci koupí po prvním nákupu trička – Decision trees (rozhodovací stromy) • je to specifický typ prediktivního modelu, je součástí strojového učení • umožňuje pochopit, jak vstupy dat ovlivňují výstupy – kombinací vytvoříme modely náhodné doménové struktury (les) 07.04.2025 5

© Květuše Sýkorová	Data mining
	• Techniky dolování dat – Statistical techniques (statistické techniky) • složité statistické techniky, doplněné o různé váhy a míry • jsou statické i dynamicky se měnící – Visualization (vizualizace) • poskytuje vhled do dat na základě smyslových vjemů • dynamické, umožňují streamování dat v reálném čase – Neural networks (neuronové sítě) • často se používá s umělou inteligencí a hlubokým učením • mají různé vrstvy, které se podobají způsobu, jakým fungují neurony v lidském mozku • některé modely neuronové sítě jsou neuvěřitelně složité 07.04.2025 6

© Květuše Sýkorová	Data mining
	• Techniky dolování dat – Data warehousing (skladování dat) • ukládání strukturovaných dat pro analýzu z hlediska business intelligence, reportingu a základních funkcí dashboardingu • cloudové DW, polostrukturované a nestrukturované úložiště – např. Hadoop – Long-term memory processing (zpracování dlouhodobé paměti) • schopnost analyzovat data po delší dobu díky DW – Machine learning and artificial intelligence (strojové učení a umělá inteligence) • jedny z nejpokročilejších vývojů v oblasti dolování dat • strojového učení, hluboké učení, ... 07.04.2025 7

© Květuše Sýkorová	Děkuji za pozornost
	07.04.2025 9