

© Květuše Sýkorová	Datová úložiště	
	Text mining	

© Květuše Sýkorová	Data x Text	
	• Data mining – extrahování užitečných informací z elektronických dat, která jsou uložena ve strukturovaném formátu tabulek / matic • Text mining – extrahování užitečných informací z elektronických dat, která jsou uložena v nestrukturovaném formátu, tj. v textových dokumentech, v <u>přirozeném jazyce</u> • knihy, emaily, webové stránky, novinové články, vědecké publikace, komunikace na sociálních sítích, recenze a komentáře k produktům,... – zkvalitní a doplní Dataminingové predikce Nestrukturované texty ➡ Strukturované atributy	

07.04.2025

2

© Květuše Sýkorová	Text mining
	• Postup: – extrahujeme skryté informace • z nestrukturovaných dokumentů – uložíme je do strukturovaných atributů databáze • přirozený jazyk -> bohatý na slova a jejich tvary => značně specifický postup extrakce • citlivý výběr atributů -> brát ohled na následné zpracování dataminingovou metodou – upravíme strukturované atributy • snížíme počet atributů (redukce) – využijeme atributy pro další zpracování / modelování • použijeme dataminingové metody 07.04.2025 3

© Květuše Sýkorová	Extrakce atributů
	• Podrobněji: – z dokumentů extrahujeme klíčová slova • slouží jako atributy (vlastnosti) dokumentů • tvoří sloupce ve strukturované matici dokumentů – Tím se nestrukturovaná textminingová úloha převede na strukturovanou dataminingovou úlohu. – komplikuje to variabilita přirozeného jazyka • malá vstupní data => velké objemy klíčových slov – jazyk = slova + slovní tvary + víceslovná hesla – získáme velkou ale řídkou matici dokumentů 07.04.2025 4

Redukce dimenzionality

© Květuše Sýkorová

- Podrobněji:
 - nutná úprava matice dokumentů
 - zanedbání některých klíčových slov
 - vhodné sloučení některých klíčových slov
 - dojde k „zahuštění“ matice dokumentů
 - snížení počtu atributů o 2-4 řády
 - např. z 10 000 atributů dostaneme 10
 - úpravu provádíme v několika krocích a různými postupy
 - neexistuje standardizovaný postup, záleží na analytikovi jaké zvolí metody a postupy
 - jazykově závislé metody z počítačové lingvistiky
 - dekompozice matic z lineární algebry
 - osvědčené modely témat
 - výběr atributů podle užitečnosti v predikčních modelech

07.04.2025

5

Redukce dimenzionality

KISS = Keep It Simple but not Stupid

© Květuše Sýkorová

- Doporučení:
 - předem si připravit několik postupů jak zredukovat atributy
 - a držet se jich
 - nezkoušet experimentování, nekonečné ladění a nastavování
 - většinou na to není dost časových a výpočetních kapacit
 - redukci dělat postupně, krok za krokem podle postupů
 - s nadhledem nad jednotlivými kroky
 - nezapomenout, proč to děláme
 - cílem JE dokumenty třídit a vybírat
 - cílem NENÍ sestavit a redukovat matici dokumentů
 - existuje velké množství postupů (NLP, LDA, LSA, NMF, SVM, ...)
 - nějaký si vybrat, nastudovat si ho, vyzkoušet a úlohu dokončit

07.04.2025

6

Postupy redukce dimenzionality

- NLP
 - Natural Language Processing
- LDA
 - Latent Dirichlet Allocation
- LSA
 - Latent Semantic Analysis
- NMF
 - Non-Negative Matrix Factorization
- SVM
 - Support Vector Machine

© Květuše Sýkorová

07.04.2025

7

Klasifikace dokumentů

- Klasifikační modely
 - jedna z metod text miningu
 - určeny pro třídění velkého množství textových dokumentů
 - několik typů modelů
 - podle počtu skupin, do kterých dokumenty roztrídíme

© Květuše Sýkorová

07.04.2025

9

Binární klasifikace dokumentů

- Binární klasifikace / binární klasifikátor
 - Třídění e-mailů spamovým filtrem
 - strukturovaná reprezentace emailů umožňuje libovolné filtrování
 - výběr a řazení podle relevance – nutné přechíst X nepodstatné (spam)
 - Klasifikace a filtrace novinových článků, tiskových zpráv, přepisů telefonních hovorů, projevů politiků, ...
 - výběr relevantních dokumentů z důvodu sledování teroristických hrozeb, prevence kriminality, sledování konkurence, monitorování vybraných kauz, ...

© Květuše Sýkorová

07.04.2025

10

Nominální klasifikace dokumentů

- Nominální klasifikace / nominální klasifikátor
 - Do organizace přichází velké množství požadavků od zákazníků
 - Požadavky zákazníků se musí dostat k osobě, která je kompetentní k jejich vyřízení
 - Manuální rozdělování je časově náročné a neefektivní
 - Model rozřadí dokumenty do kategorií, které odpovídají kompetencím jednotlivých pracovníků zodpovědných za vyřizování určitého druhu požadavků

© Květuše Sýkorová

07.04.2025

11

Vícečetná klasifikace dokumentů

- Vícečetná klasifikace / vícečetný klasifikátor
 - Případy, kdy každý textový dokument můžeme zařadit do více kategorií zároveň
 - Textové odpovědi na otevřené otázky ve výzkumech => více důvodů nespokojenosti se službami, výrobky, ...
 - Odborné články => věnují se více tématům najednou

Děkuji za pozornost