

Loess regrese a mnohonásobná regrese


Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Loess regrese


Loess (nebo LOWESS, z anglického "Locally Weighted Scatterplot Smoothing") je neparametrická regresní technika, která kombinuje několik regresních modelů v meta-modelu založeném na metodě k-nejbližších sousedů. Na rozdíl od lineární nebo logistické regrese, které modelují vztah jedním rovnicí, Loess aplikuje několik regresí v lokálních podmnožinách dat. Tento přístup umožňuje Loess modelovat složitější, nelineární vztahy, které se mohou lišit v různých rozsazích dat.



Klíčové charakteristiky regrese Loess:


- **Lokální regrese:** Loess modeluje jednoduché modely na lokálních podmnožinách dat, což je efektivní pro modelování složitých, nelineárních vztahů.
- **Vážené nejmenší čtverce:** V každé lokální podmnožině Loess používá vážené nejmenší čtverce, přičemž větší váhu přiřazuje bodům nejbližším k cílovému bodu, pro který je model stavěn.
- **Parametr vyhlazování (šířka pásma):** Stupeň vyhlazování je řízen parametrem, často nazývaným šířka pásma nebo rozpětí, který určuje, kolik dat je použito pro vytvoření každého lokálního modelu. Větší šířka pásma zahrnuje více bodů a vede k hladší křivce.
- **Flexibilita:** Loess může zachytit různé druhy struktur v datech bez předpokladu konkrétní globální formy (jako je linearita) pro vztah mezi proměnnými.
- **Výpočetní náročnost:** Vyžaduje více výpočetního výkonu než jednoduchá lineární regrese, zejména pro velké datové sady, protože zahrnuje vytváření mnoha malých modelů.
- **Robustnost:** Pro lepší robustnost vůči outlierům je možné použít Loess s robustní váhovou funkcí, která zmenšuje váhy pro odlehlé hodnoty.

Loess regrese: Local regrese




Loess regrese: Loess curve

Loess Regression: Aggregation of Local Models



Loess regrese: Loess prediction

Loess Regression: Prediction on Test Data



Interpretace:

- **Identifikace trendů:** Loess regrese se primárně používá pro vizualizaci trendu v datech.
- **Bez koeficientů:** Na rozdíl od lineární regrese Loess nevýsledkuje v jednoduché rovnici nebo koeficientech pro prediktory. Výstupem je hladká křivka, která reprezentuje vztah.

Aplikace:

- **Vizualizace dat:** Často se používá v explorativní analýze dat k vizualizaci trendu v datovém souboru.
- **Nelineární vztahy:** Užitečné, pokud je vztah mezi proměnnými známý jako nelineární, nebo když chcete prozkoumat povahu vztahu bez předpokladu linearity.
- **Ekonometrie a epidemiologie:** Loess se široce používá v různých vědeckých oborech, včetně ekonometrie, epidemiologie a sociálních věd, kde je třeba analyzovat složité, nelineární vztahy mezi proměnnými.

Omezení:

- **Subjektivita:** Volba šířky pásma/vyhlažovacího parametru může být do jisté míry subjektivní a výrazně ovlivňuje výsledný fit.
- **Přetrénování:** Existuje riziko přetrénování, pokud je šířka pásma příliš malá, což vede k modelu, který je příliš úzce vázán na šum v datech.
- **Extrapolace:** Loess není vhodný pro extrapolaci mimo rozsah dat.
- **Vícedimenzionální data:** Zatímco Loess funguje dobře pro univariátní a bivariátní data, jeho aplikace se stává složitější a výpočetně náročnější pro vyšší dimenze dat.
- **Vysoká složitost:** Pro velké soubory dat může být Loess výpočetně náročný, což omezuje jeho použití v reálných časech.

Úvod do mnohonásobné regrese

Mnohonásobná regresní analýza je statistická metoda, která umožňuje analyzovat vztah mezi jednou závislou proměnnou a více nezávislými proměnnými. Tato technika je široce používána v různých oblastech, včetně ekonomie, medicíny a sociálních věd, k odhalování potenciálních příčinných vztahů mezi proměnnými. Základní pojmy:

- **Závislá proměnná (Y):** Proměnná, kterou chceme vysvětlit nebo předpovědět.
- **Nezávislé proměnné (X_i):** Proměnné, které používáme k předpovídání nebo vysvětlení závislé proměnné.
- **Koeficienty (β_i):** Reprezentují míru změny závislé proměnné při změně příslušné nezávislé proměnné o jednotku.
- **Chybový člen (ϵ):** Reprezentuje část závislé proměnné, kterou nelze vysvětlit pomocí modelu.

Matematický model

Model mnohonásobné regrese můžeme matematicky vyjádřit jako:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_n X_n + \epsilon \quad (1)$$

Tento model nám říká, že závislá proměnná Y je lineární funkcí nezávislých proměnných $X_1, X_2, \dots, X_n$, přičemž β_0 je y-intercept (bod, kde regresní přímka protíná y-ovou osu), $\beta_1, \beta_2, \dots, \beta_n$ jsou sklonové koeficienty jednotlivých nezávislých proměnných, a ϵ je chybový termín.

Předpoklady mnohonásobné regrese

Pro validní výsledky mnohonásobné regresní analýzy musí být splněny následující předpoklady:

1. Lineární vztah mezi závislými a nezávislými proměnnými.
2. Nezávislost reziduí (chybových členů).
3. Homoskedasticita reziduí (konstantní rozptyl chybových členů).
4. Normální rozdělení reziduí.
5. Žádná nebo minimální multikolinearita mezi nezávislými proměnnými.

Míra těsnosti lineární závislosti náhodné veličiny Y na vektoru X

Definice Koeficientu Mnohonásobné Korelace:

$$\rho_{Y.X}^2 = \text{cor}(Y, X) \text{cor}(X)^{-1} \text{cor}(X, Y) \quad (2)$$

- $\text{cor}(Y, X)$ - korelační matice veličiny Y a vektoru X .
- $\text{cor}(X)$ - korelační matice vektoru X .

Výběrový Koeficient Mnohonásobné Korelace:

$$r_{Y.X}^2 = RYX R^{-1} RXY \quad (3)$$

- RYX - výběrová korelační matice veličiny Y a vektoru X .
- R - výběrová korelační matice vektoru X .

Index Korelace v Regresním Modelu

- $r_{Y.X}^2$ odpovídá indexu determinace v regresním modelu $Y = X\beta + \varepsilon$.
- F-test je rovnocenný s testem o nulové hodnotě $r_{Y.X}$.

Podmínky pro Kvalitní Regresní Model

- Hodnota testové statistiky F by měla být aspoň 4x větší než kvantil Fisherova - Snedecorova rozložení.

Posouzení Vlivu Jednotlivých Nezávisle Proměnných

Porovnání vlivu proměnných $x_1, \dots, x_p$ na závislou proměnnou Y v modelu $Y = X\beta + \varepsilon$ pomocí standardizovaných regresních parametrů (B-koeficientů).

- **Definice B-Koeficientů:** B-koeficienty se získávají ze standardizovaných veličin:

$$Z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad Z_{iY} = \frac{Y_i - \bar{Y}}{s_Y} \quad (4)$$

kde $j = 1, \dots, p$, $i = 1, \dots, n$, a model se přeformuluje s těmito standardizovanými proměnnými.

- **Význam B-Koeficientů:** Odhady regresních parametrů ve standardizovaném modelu, tj. B-koeficienty, ukazují intenzitu vlivu nezávisle proměnných veličin na Y .

Použití Parciálních Korelačních Koeficientů v Mnohonásobné Lineární Regresi

- **Model Mnohonásobné Lineární Regrese.** Uvažujeme model

$$Y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i, i = 1, \dots, n \quad (5)$$

- **Parciální Index Determinace.** Druhá mocnina výběrového parciálního korelačního koeficientu $(r_{Y, x_j \cdot x_1 \dots x_{j-1}})^2$ se nazývá parciální index determinace, indikující „čistý“ přínos proměnné x_j do modelu.
- **Význam Parciálních Korelačních Koeficientů.** Výběrový parciální korelační koeficient měří „čistou“ korelaci mezi Y a X_j , eliminující vliv ostatních proměnných. To nám umožňuje hodnotit přímý vliv každé proměnné na závislou proměnnou Y .
- **Vztah mezi ST, SR a SE.** Ve vzorci $ST = SR + SE$ představuje pokles reziduálního součtu čtverců (SE) při zařazení nové proměnné do modelu růst regresního součtu čtverců (SR), ukazující na význam přidané proměnné vzhledem k dříve zařazeným proměnným.

Algoritmus Postupné Regrese

1. Výběr Prvního Regresoru.

- Vypočítáme korelační koeficienty mezi Y a všemi regresory $x_1, \dots, x_p$.
- Vybereme regresor x_i s největší absolutní hodnotou korelačního koeficientu.

2. Testování Prvního Modelu.

- Sestavíme model $Y = \beta_0 + \beta_1 x_i$, odhadneme koeficienty metodou nejmenších čtverců.
- Vypočítáme SR , SE a testové kritérium $F = \frac{SR}{SE/(n-2)}$.
- Pokud $F \geq F_{1-\alpha}(1, n-2)$, zařadíme x_i do modelu.

3. Výběr Druhého Regresoru.

- Vypočítáme parciální korelační koeficienty mezi Y a regresory nezařazenými do modelu, očištěné o vliv x_i .
- Vybereme x_j s největší absolutní hodnotou parciálního korelačního koeficientu.

Algoritmus Postupné Regrese

4. Testování Modelu s Dvěma Regresory.

- Sestavíme model $Y = \beta_0 + \beta_1 x_i + \beta_2 x_j$, odhadneme koeficienty.
- Vypočítáme SR , SE a $F = \frac{\Delta SR}{SE/(n-3)}$, kde ΔSR je přírůstek SR při zařazení x_j .
- Pokud $F \geq F_{1-\alpha}(1, n-3)$, zařadíme x_j do modelu.


5. Krok 5 a další.

- Opakujeme kroky 3 a 4 pro další regresory, dokud nevyčerpáme všechny možnosti.
- V každém kroku vypočítáme parciální korelační koeficienty pro zbylé regresory, očištěné o vliv již zařazených regresorů.
- Postupujeme dle stejného testovacího kritéria jako v předchozích krocích.


1. Tečkové Diagramy.

- Sestrojíme dvourozměrné tečkové diagramy pro dvojice (Y, x_j) , kde $j = 1, \dots, p$.
- Hledáme známky lineární závislosti mezi Y a každým x_j .
- Zvláštní tvary diagramů mohou indikovat problémy jako heteroskedasticitu.

Ukázka homoskedastických dat:




Ukázka dat s rostoucí heteroskedasticitou:




Postup při budování modelu mnohonásobné lineární regrese

Ukázka dat s klesající heteroskedasticitou:



Ukázka dat s proměnlivou heteroskedasticitou:



2. Korelační Koeficienty.

- Vypočteme výběrové párové a parciální korelační koeficienty mezi Y a x_j .
- Porovnání párových a parciálních koeficientů může odhalit multikolinearitu.

3. Odhady a Testování.

- Získáme odhady regresních koeficientů, index determinace, a odhad rozptylu.
- Provedeme dílčí t-testy a celkový F-test.
- Vliv jednotlivých proměnných posoudíme pomocí B-koeficientů.

4. Vyloučení Proměnných.

- Z modelu vyloučíme proměnné s nevýznamnými dílčími t-testy.
- Zaměříme se na proměnné s významným přínosem k vysvětlení variability Y .

Příklad

Šest studentů gymnázia absolvovalo čtyři testy, které měří následující veličiny:

- X_1 - přírodovědné vědomosti,
- X_2 – literární vědomosti,
- X_3 – schopnost koncentrace,
- X_4 – logické myšlení. Testy se hodnotí na škále od 1 do 10 (1 = špatný výsledek, 10 = výborný výsledek).

student	X_1	X_2	X_3	X_4
1	7	9	10	8
2	9	8	8	10
3	4	3	1	2
4	2	3	2	2
5	3	1	2	4
6	1	1	1	4

Zajímá nás, kolik bodů můžeme očekávat v testu koncentračních schopností studenta, jestliže známe výsledky testů pro literární schopnosti, přírodovědné schopnosti a logické myšlení.