

Téma 1. Obecné regresní modely: lineární, polynomiální a nelineární regresní modely

Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem


sergii.babichev@ujep.cz

1 Lineární, polynomiální a nelineární regresní modely

- Typy regresních modelů
- Cíle regresní analýzy a aplikace
- Korelační a regresní analýza
- Jednoduchý lineární regresní model
- Model polynomiální regrese
- Nelineární regresní model

2 Metody hodnocení kvality regresního modelu



Typy regresních modelů



Regresní analýza

Závislost mezi kvantitativními proměnnými X a Y:

- Funkční závislost – hodnotami nezávisle proměnných je jednoznačně dána hodnota závislé proměnné: $Y=f(X)$
- Stochastická (volná) závislost – systematický pohyb jedné veličiny při růstu či poklesu druhé veličiny



Cíle regresní analýzy

- Identifikace vztahů mezi proměnnými
- Predikce hodnot závislé proměnné
- Odhalení klíčových faktorů ovlivňujících výsledky
- Optimalizace rozhodovacích procesů

Aplikace:

- Ekonometrie: predikce cen, analýza trhu;
- Biostatistika: modelování závislosti mezi zdravotními faktory;
- Strojové učení: regresní modely pro predikci;
- Fyzika a chemie: analýza experimentálních dat.

Korelační a regresní analýza

Vyhodnocují vztah mezi spojitými veličinami:

- Nekauzální vztahy (neznáme příčinu a důsledek) – korelační analýza;
- Kauzální vztahy (víme co je příčina a co je následek) – korelační i regresní analýza.

Nezávisle proměnná (vysvětlující proměnná) – vysvětluje chování závislé proměnné (příčina);

Závisle proměnná (vysvětlovaná proměnná) – proměnná jejíž chování se snažíme vysvětlit (následek)

Typy regrese

- Jednoduchá regrese - studuje kauzální závislost dvou veličin (velikost syna na velikosti otce);
- Vícenásobná regrese - studuje kauzální závislost jedné veličiny na alespoň dvou dalších veličinách (velikost syna na velikosti otce a matky).

Typy regrese


- Polynomiální regrese. Základem tohoto modelu je polynomiální funkce:

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n + \varepsilon$$

- Nelineární regrese. Tento typ modelu je založen na jiném typu funkce s jedním nebo více parametry (například $y = ae^{bx}$).
- Logistická regrese. Tento typ modelu se používá pro simulaci pravděpodobnosti existence určité třídy nebo události. Každé detekované události by byla přiřazena pravděpodobnost mezi 0 a 1 a součet všech pravděpodobností by v tomto případě měl být roven jedné.

Regresní analýza

Korelační pole



Jednoduchý lineární regresní model

Vyrovňovací křivka:

$$Y_i = \beta_0 + \beta_1 x_i + e_i$$

Parametry modelu

Reziduum
Náhodná složka –
popisuje vliv
náhodných nebo
nepozorovaných
regresorů a vliv
náhody


Výška otce

Vysvětlující (nezávisle) proměnná

Jednoduchý lineární regresní model



a) Scatter plot of two-dimensional data



b) Fitted line of a simple regression model

Jednoduchý lineární regresní model

Kritériem "nejlepší" funkční predikce je minimalizace součtu čtverců odchylek empirických hodnot y od teoretických hodnot získaných regresní rovnicí Y :

$$S(a, b) = \sum_{i=1}^n (Y_i - y_i)^2 = \sum_{i=1}^n (a + bx_i - y_i)^2 \rightarrow \min$$

$$\frac{\partial S}{\partial a} = 2 \sum_{i=1}^n (a + bx_i - y_i) = 0; \quad \frac{\partial S}{\partial b} = 2 \sum_{i=1}^n (a + bx_i - y_i)x_i = 0$$


$$na + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i; \quad a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

$$b = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}; \quad a = \frac{\sum_{i=1}^n y_i \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n x_i y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}.$$

Model polynomiální regrese

Polynomiální regrese je regresní model, který je lineární v parametrech, ale popisuje nelineární závislost mezi proměnnými podle rovnice:

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n + \varepsilon$$



Model polynomiální regrese

Množinu koeficientů b_i lze také nalézt na základě metody nejmenších čtverců:

$$S(b_0, b_1, \dots, b_k) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k)^2 \rightarrow \min$$

$$\frac{\partial S(b_0, b_1, \dots, b_n)}{\partial b_j} = 0, \quad j = 1 \dots k$$

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-1) = 0$$

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-x_i) = 0$$

.....

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-x_i^k) = 0$$

Nelineární regresní model

Nelineární regrese je regrese, ve které jsou závislé nebo kriteriální proměnné modelovány jako nelineární funkce parametrů modelu a jedné nebo více nezávislých proměnných. Nelineární regrese používá nelineární regresní rovnice, které mají tvar:


$$Y = f(X, \beta) + \varepsilon,$$

kde: X je vektor p prediktorů; β je vektor k parametrů; $f(\cdot)$ je známá regresní funkce; ε je chybový termín. Jako regresní lze použít následující funkce:


- asymptotická funkce 1: $y = \frac{ax}{1 + bx}$;
- asymptotická funkce 2: $y = a(1 - \exp(-bx))$;
- hyperbolická funkce: $y = a + \frac{b}{x}$;
- logistická funkce: $y = \frac{1}{a + b \cdot \exp(-x)}$.

Nelineární regresní model


a) Asymptotic function 1




b) Asymptotic function 2



c) Hyperbolic function



d) Logistic function



Moderní metody hodnocení kvality regresních modelů

Hodnocení kvality regresních modelů je klíčovým krokem v analýze dat. Používají se následující metriky:

- **Střední kvadratická chyba (MSE)**

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$

kde:

- n – počet pozorování,
- y_i – skutečná hodnota i -tého pozorování,
- $\hat{y}_i$ – predikovaná hodnota i -tého pozorování.

- **Kořenová střední kvadratická chyba (RMSE)**

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

- **Koeficient determinace (R^2)**

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

kde:

- $\bar{y}$ – průměrná hodnota všech skutečných hodnot.

- **Mean Absolute Error (MAE)**

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4)$$

Každá z těchto metrik má své specifické použití a interpretaci. RMSE a MSE jsou citlivé na velké odchylky, zatímco MAE poskytuje průměrnou absolutní chybu.

- **MSE a RMSE** – vhodné pro modely, kde jsou extrémní hodnoty důležité, ale RMSE je srozumitelnější díky stejným jednotkám jako cílová proměnná.
- **MAE** – méně citlivé na extrémy, poskytuje průměrnou absolutní chybu.
- R^2 – měří, jak dobře model vysvětluje variabilitu dat, hodnota blízká 1 znamená dobrý model.

Použití správné metriky závisí na specifickém problému a požadavcích analýzy.