

Logistická a ML-based regresní modely

Sergii Babichev


Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Definice:

- Logistická regrese je statistická metoda používaná pro predikci binárních výsledků (1/0, Ano/Ne, Pravda/Nepravda) z jedné nebo více prediktorových proměnných.
- Modeluje pravděpodobnost výskytu události pomocí logistické funkce, což je S-křivka.

$$y = \frac{1}{1 + e^{-x}}$$



Porovnání s lineární regresí:

- Lineární regrese se používá pro predikci spojitých výsledků, zatímco logistická regrese se používá pro binární (nebo kategoriální) výsledky.
- Lineární regrese předpokládá lineární vztah mezi nezávislými proměnnými a závislou proměnnou. Logistická regrese modeluje pravděpodobnost, že závislá proměnná patří do určité kategorie.

Logistická regrese je vhodná, když:

- Cílová proměnná je binární.
- Potřebujete odhadnout pravděpodobnost výskytu události v závislosti na jedné nebo více nezávislých proměnných.
- Chcete vyhodnotit význam nezávislých proměnných na pravděpodobnost výskytu události.

Matematický model logistické regrese:

- Logistická regrese modeluje pravděpodobnost $P(Y = 1)$ jako funkci nezávislých proměnných, X .
- Matematický model lze zapsat jako:

$$P(Y = 1|X) = \frac{e^{(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}} \quad (1)$$

- Kde $\beta_0, \beta_1, \dots, \beta_k$ jsou koeficienty modelu.

Logit funkce a logistická funkce:


- **Logit funkce** je logaritmus šance (odds) na výskyt události:

$$\log \left(\frac{P(Y = 1)}{1 - P(Y = 1)} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

- **Logistická funkce** je inverze logit funkce, což nám dává pravděpodobnost:

$$P(Y = 1|X) = \frac{e^{(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

- Tato transformace zajišťuje, že výstup modelu je vždy mezi 0 a 1, což je interpretováno jako pravděpodobnost.



Význam a interpretace koeficientů:

- Koeficienty (β) modelu quantifikují vztah mezi nezávislými proměnnými a logaritmem šance na výskyt události.
- Pozitivní koeficient naznačuje, že s rostoucí hodnotou proměnné roste pravděpodobnost výskytu události.
- Negativní koeficient naznačuje opak: s rostoucí hodnotou proměnné pravděpodobnost výskytu události klesá.
- Hodnota $\exp(\beta_i)$ může být interpretována jako změna šance na výskyt události s jednotkovou změnou v i -té proměnné, při držení ostatních proměnných konstantní.

Odhad parametrů modelu:

- Prediktorové proměnné (nebo nezávislé proměnné) jsou vstupy do modelu, které používáme pro predikci výsledků.
- Odpovědní proměnná (nebo závislá proměnná) je výstup, který chceme predikovat, typicky binární v tomto kontextu.
- Výběr správných prediktorů je kritický pro úspěch modelu a vyžaduje pochopení domény problému.

Stanovení prediktorů a odpovědní proměnné:

- Po definování modelu a výběru proměnných je dalším krokem odhadnutí koeficientů modelu (β).
- Koeficienty určují sílu a směr vztahu mezi každou nezávislou proměnnou a log-šancemi výskytu události.
- Odhady koeficientů se obvykle získávají metodou maximální věrohodnosti, která najde takové hodnoty koeficientů, které maximalizují pravděpodobnost pozorovaných dat za daných podmínek.

Maximální věrohodnostní odhad:

- Maximální věrohodnostní odhad (MLE) je metoda používaná k nalezení odhadů parametrů statistického modelu, které by nejvíce pravděpodobně vyprodukovaly pozorovaná data.
- V kontextu logistické regrese MLE iterativně upravuje koeficienty, aby maximalizovala logaritmickou věrohodnostní funkci přes všechna pozorování.
- Výsledkem je sada koeficientů, která nejlépe vysvětluje vztah mezi nezávislými proměnnými a pravděpodobností výskytu události.

Příklad použití MLE. Představme si, že máme dataset s jednou nezávislou proměnnou X a binární odpovědní proměnnou Y , a chceme použít logistickou regresi pro modelování pravděpodobnosti $P(Y = 1|X)$.

Logistická regresní funkce je dána jako:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

kde β_0 a β_1 jsou koeficienty modelu, které potřebujeme odhadnout.

Funkce log-věrohodnosti pro logistickou regresi

- **Pravděpodobnostní model.** Pro každé pozorování i , model logistické regrese předpokládá, že:

$$P(Y_i = 1|X_i) = p_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_i)}}$$

a tedy

$$P(Y_i = 0|X_i) = 1 - p_i = \frac{e^{-(\beta_0 + \beta_1 X_i)}}{1 + e^{-(\beta_0 + \beta_1 X_i)}}$$

- **Likelihood funkce** pro n nezávislých pozorování je součinem individuálních pravděpodobností:

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$

kde y_i je hodnota Y_i (0 nebo 1) pro i -té pozorování.

Funkce log-věrohodnosti pro logistickou regresi

- **Funkce log-věrohodnosti.** Logaritmujeme likelihood funkci, abychom získali log-věrohodnostní funkci, což zjednodušuje výpočty:

$$\ell(\beta) = \log(L(\beta)) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (2)$$

- **Maximalizace log-věrohodnosti.** Cílem je najít hodnoty β_0 a β_1 , které maximalizují $\ell(\beta)$. Toto se obvykle provádí numerickými metodami, jako je Newton-Raphsonova metoda nebo gradientní vzestup, protože přímé řešení může být komplexní.
- Derivace $\ell(\beta)$ vůči β_0 a β_1 poskytují gradient funkce, který se používá k iterativnímu hledání maxima.
- Po nalezení optimálních hodnot $\hat{\beta}_0$ a $\hat{\beta}_1$, můžeme tyto koeficienty použít pro predikci pravděpodobností a interpretovat vztah mezi X a Y . Například, kladný koeficient $\hat{\beta}_1$ znamená, že s nárůstem X , pravděpodobnost $Y = 1$ roste.

Metriky pro hodnocení modelu:

- **Akaikeho informační kritérium (AIC)** - měří kvalitu modelu s ohledem na počet parametrů. Nižší AIC značí lepší model.
- **R² McFaddena** - varianta R² používaná pro logistickou regresi, měří míru vysvětlené variability modelu.
- Matice záměny a hodnotící metriky:
 - **Matice záměny** - tabulka, která ukazuje skutečné vs. předpovězené klasifikace.
 - **Přesnost** - podíl správně klasifikovaných případů.

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Sensitivita (Recall)** - schopnost modelu správně identifikovat pozitivní případy.

$$RC = \frac{TP}{TP + FN}$$

- **Specificita** - schopnost modelu správně identifikovat negativní případy.



$$SP = \frac{TN}{TN + FP}$$

Hodnocení modelu logistické regrese

ROC křivka a AUC hodnota:

- **ROC křivka** (Receiver Operating Characteristic) - grafické znázornění vztahu mezi sensitivitou a (1-specificita) pro různé práhové hodnoty.
- **AUC hodnota** (Area Under the Curve) - měří celkovou schopnost modelu správně klasifikovat případy nezávisle na práhové hodnotě. Hodnota 1 značí dokonalý model, hodnota 0.5 značí model bez prediktivní schopnosti.

$$ROC : senc = f(1 - spec)$$



Definice 1: Strom — Strom je souvislý graf $T = (V, E)$, který neobsahuje žádné cykly. V , označované také jako $V(T)$, je množina vrcholů a E , označované také jako $E(T)$, je množina hran (tj. dvojic prvků z množiny $V(T)$).

Listy stromu T jsou ty vrcholy z $V(T)$, které mají stupeň 1 (vede z nich právě jedna hrana). Množinu všech listových vrcholů stromu T budeme označovat jako $V_L(T)$. Množinu všech nelistových vrcholů (uzlů) budeme označovat jako $V_U(T)$.

Definice 2: Kořenový strom — Kořenový strom je dvojice (T, r) , kde T je strom a $r \in V(T)$ se nazývá kořen stromu T .

Vrchol $v \in V(T)$ je rodičem vrcholu $s \in V(T)$, pokud $\{v, s\} \in E(T)$ a vrchol v leží na jediné cestě mezi kořenem a vrcholem s .

Hranu s rodičovským vrcholem v a potomkem s budeme dále označovat jako uspořádanou dvojici $(v, s) \in E(T)$.

Definice: Rozhodovací strom

Nechť:

- A je množina atributů (vstupní proměnné),
- $Values(a)$ je množina hodnot atributu a ,
- C je množina tříd (cílových kategorií).

Rozhodovací strom je struktura, která:

- přiřazuje atribut každému vnitřnímu uzlu,
- přiřazuje konkrétní hodnotu atributu každé hraně,
- přiřazuje výslednou třídu každému listu.

Formálně jej zapíšeme jako čtveřici:

$$((T, r), f_A, f_V, f_C)$$

Formální definice zobrazení v rozhodovacím stromu

- **Struktura stromu:**

$$(T, r)$$

kde T je strom a r je kořen, přičemž $r \notin V_L(T)$.

- **Zobrazení atributů:**

$$f_A : V_U(T) \rightarrow A$$

Každému vnitřnímu uzlu je přiřazen právě jeden atribut.

- **Zobrazení hodnot na hranách:**

$$f_V : E(T) \rightarrow \text{Values}(A)$$

Každá hrana odpovídá konkrétní hodnotě atributu rodičovského uzlu.

- **Zobrazení tříd v listech:**

$$f_C : V_L(T) \rightarrow C$$

Každý list obsahuje výslednou klasifikaci.

Základní model rozhodovacího stromu

Definice 4: Úplný rozhodovací strom — Úplný rozhodovací strom $((T, r), f_A, f_H, f_C)$ je rozhodovací strom, který splňuje:

$$\forall v \in V_U(T) \forall h \in \text{Values}(f_A(v)) \exists e \in E(T) (e = (v, v_2)) : f_H(e) = h$$

- každý vnitřní uzel testuje určitý atribut,
- pro **každou možnou hodnotu** tohoto atributu existuje odpovídající hrana,
- žádná hodnota atributu tedy není „vynechána“.

Jinými slovy: *Z každého vnitřního uzlu musí vycházet právě tolik hran, kolik má daný atribut možných hodnot.*


Význam jednotlivých částí:

- $v \in V_U(T)$ — každý vnitřní uzel,
- $h \in \text{Values}(f_A(v))$ — každá možná hodnota atributu v tomto uzlu,
- $\exists e$ — existuje odpovídající hrana,
- $f_H(e) = h$ — hrana reprezentuje právě tuto hodnotu.


Základní model rozhodovacího stromu: Příklad

Student	Je populární	IQ	Doba studia	Průměrná známka	Složil zkoušku
Anna K.	Ano	Průměrné	Více než 4 dny	1.3	Ano
Milan H.	Ne	Průměrné	Více než 4 dny	2.0	Ano
Ladislav G.	Ne	Nadprůměrné	Méně než 4 dny	3.1	Ne
Jan D.	Ne	Podprůměrné	Více než 4 dny	3.2	Ano
Jan T.	Ano	Podprůměrné	Méně než 4 dny	2.9	Ano
Buhumír F.	Ano	Průměrné	Méně než 4 dny	2.5	Ano
Libuše R.	Ano	Průměrné	Méně než 4 dny	3.0	Ano
Rudolf J.	Ano	Průměrné	Nestudoval	1.4	Ne

Rozhodovací strom 1



Rozhodovací strom 2



Regresor vs. Klasifikátor

Vlastnost	Klasifikátor	Regresor
Typ výstupu	Diskrétní třídy	Spojité číselné hodnoty
Cíl	Přiřazení vzorků ke třídám	Predikce číselného výsledku
Kritérium dělení	Giniho nečistota, Entropie	Střední kvadratická chyba (MSE), Střední absolutní chyba (MAE)
Hodnota listového uzlu	Nejčastější třída	Průměr (nebo medián) cílových hodnot
Použití	Klasifikační úlohy	Regresní úlohy

Matematická formulace:

- **Klasifikace:** Predikovaná třída v listovém uzlu je určena jako:

$$\hat{y} = \arg \max_c P(y = c) \quad (3)$$

kde $P(y = c)$ je pravděpodobnost třídy c .

- **Regrese:** Predikovaná hodnota v listovém uzlu je průměrná hodnota:

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N y_i \quad (4)$$