

Úvod do Bayesovských sítí a Bayesovské statistiky

Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Cíl úlohy:

- Samostatně vytvořit Bayesovskou síť v programu **GeNIe** na základě příkladu uvedeného na konci prezentace.
- Model bude reprezentovat odhad skrytého stavu pomocí několika pozorování.
- Úkolem je:
 - definovat strukturu sítě,
 - zadat apriorní pravděpodobnosti,
 - vyplnit podmíněné pravděpodobnosti,
 - zadat evidence,
 - interpretovat výsledné posteriorní pravděpodobnosti.

Poznámka: Použijte stejný příklad jako v prezentaci: 5 hypotéz a 6 pozorování.

Krok 1: Vytvoření struktury sítě

- 1 Otevřete program **GeNIe**.
- 2 Vytvořte nový projekt (*File* → *New*).
- 3 Přidejte jeden hlavní diskrétní uzel s názvem:

Hypothesis

- 4 Tento uzel bude reprezentovat skrytý stav systému (např. H_1, H_2, H_3, H_4, H_5).
- 5 Dále vytvořte 6 diskrétních uzlů pro jednotlivá pozorování:
 - EyeContact
 - Smile
 - AskedForDrink
 - LooksAtOtherMen
 - ShortPhrases
 - MakeUpBathroom
- 6 Vytvořte orientované hrany z uzlu Hypothesis do všech uzlů pozorování.

Výsledná struktura: jeden rodičovský uzel a několik dceřiných uzlů (naivní Bayesovský model).

Krok 2: Definice stavů uzlů

Uzel Hypothesis:

- Definujte 5 stavů:

H_1, H_2, H_3, H_4, H_5

- Například:

- H_1 : Totally dislikes
- H_2 : Dislikes
- H_3 : Neutral
- H_4 : Likes
- H_5 : In love

Uzly pozorování:

- Pro každý uzel zadejte dva stavy:

Yes, No

- Stav Yes znamená, že dané pozorování nastalo.
- Stav No znamená, že dané pozorování nenastalo.

Doporučení: Používejte stručné a jednoznačné názvy uzlů i stavů.

Krok 3: Zadání apriorních pravděpodobností

Pro uzel Hypothesis zadejte apriorní rozdělení:

$$P(H) = [0.10, 0.15, 0.50, 0.20, 0.05]$$

Postup v GeNIe:

- 1 Klikněte na uzel Hypothesis.
- 2 Otevřete tabulku pravděpodobností (*Definition*).
- 3 Do jednotlivých stavů vložte hodnoty:

Stav	Pravděpodobnost
H_1	0.10
H_2	0.15
H_3	0.50
H_4	0.20
H_5	0.05

- 4 Zkontrolujte, že součet pravděpodobností je roven 1.

Interpretace: Jde o počáteční důvěru v jednotlivé hypotézy před zadáním evidence.

Krok 4: Zadání podmíněných pravděpodobností

Pro každý uzel pozorování vyplňte tabulku

$$P(E_k \mid H_i)$$

na základě hodnot uvedených v prezentaci.

Příklad pro uzel EyeContact:

Hypothesis	$P(\text{Yes} \mid H_i)$	$P(\text{No} \mid H_i)$
H_1	0.10	0.90
H_2	0.20	0.80
H_3	0.40	0.60
H_4	0.20	0.80
H_5	0.10	0.90

Stejným způsobem vyplňte i další uzly:

- Smile
- AskedForDrink
- LooksAtOtherMen
- ShortPhrases
- MakeUpBathroom

Důležité: Pro každý stav rodičovského uzlu musí platit:

Krok 5: Zadání evidence a výpočet posteriorních pravděpodobností

Po vytvoření modelu zadejte evidence.

- 1 Vyberte některý uzel pozorování.
- 2 Nastavte pozorovaný stav, například:

EyeContact = Yes

- 3 GeNIe automaticky přepočítá posteriorní rozdělení uzlu Hypothesis.
- 4 Sledujte, jak se změní pravděpodobnosti stavů $H_1, \dots, H_5$.

Další experimenty:

- Zadejte pouze jednu evidenci.
- Poté kombinujte více evidencí současně.
- Porovnejte výsledky pro různé kombinace pozorování.

Cíl: Zjistit, která hypotéza má po zadání evidence nejvyšší posteriorní pravděpodobnost.

Krok 6: Interpretace výsledků

Po vytvoření a otestování sítě odpovězte na následující otázky:

- 1 Která hypotéza měla nejvyšší apriorní pravděpodobnost?
- 2 Jak se změnila distribuce pravděpodobností po zadání jedné evidence?
- 3 Která evidence ovlivňuje výsledek nejvíce?
- 4 Jak se změní posteriorní rozdělení při kombinaci více pozorování?
- 5 Je výsledná hypotéza stabilní, nebo se výrazně mění podle zadané evidence?

Cíl: vytvořit a otestovat diskrétní Bayesovskou síť (BN) pro jednoduchý doménový příklad **Animals**

Vstupní data: tabulka případů (cases), každý řádek je jedna pozorovaná situace.

Atributy (diskrétní proměnné):

- `Animal` $\in \{\text{Monkey, Penguin, Platypus, Robin, Turtle}\}$
- `Environment` $\in \{\text{Air, Land, Water}\}$
- `Class` $\in \{\text{Bird, Mammal, Reptile}\}$
- `BearsYoungAs` $\in \{\text{Eggs, Live}\}$
- `BodyCovering` $\in \{\text{Hair, Down, Scales}\}$
- `HasShell` $\in \{\text{True, False}\}$
- `WarmBlooded` $\in \{\text{True, False}\}$

Úloha: z dat naučit tabulky podmíněných pravděpodobností (CPT).

Krok 1: Návrh struktury BN (DAG)


Navrhňte směrovaný acyklický graf (DAG) odpovídající doménové logice.

Doporučená struktura:

- `Animal` $\rightarrow$ `Environment`
- `Animal` $\rightarrow$ `Class`
- `Animal` $\rightarrow$ `BearsYoungAs`
- `Class` $\rightarrow$ `WarmBlooded`
- `Class` $\rightarrow$ `BodyCovering`
- `Class` $\rightarrow$ `HasShell`

Kontrola: graf nesmí obsahovat cyklus (např. $A \rightarrow B \rightarrow A$).

Návrh struktury BN



Krok 2: Vytvoření BN v GeNIe (uzly a stavy). Definice hran (závislostí) v GeNIe

Postup v GeNIe:

- 1 Vytvořte nový projekt a vložte uzly pro všechny proměnné.
- 2 U každého uzlu nastavte **Type = Chance** (žlutý uzel).
- 3 Nastavte **States** přesně podle domény dat (včetně názvů).
- 4 Přidejte hrany dle DAG:
 - 1 Spojte Animal se Environment, Class, BearsYoungAs.
 - 2 Spojte Class se WarmBlooded, BodyCovering, HasShell.

Pozor na názvy: názvy uzlů musí přesně odpovídat názvům sloupců v datech (např. WarmBlooded, HasShell, BodyCovering bez mezer).

Kontrola rodičů: u uzlu X ověřte, že množina rodičů $\text{Pa}(X)$ je správná. Např. $\text{Pa}(\text{BodyCovering}) = \{\text{Class}\}$.

Krok 3: Import dat (Cases) do GeNIe. Učení parametrů (CPT) v GeNIe

Import tabulky případů:

- 1 Otevřete **Data/Cases**.
- 2 Vyberte soubor `Animals_train.txt` a nastavte oddělovač (whitespace / tab).
- 3 Ověřte mapování sloupců na uzly (jména musí sedět 1:1).
- 4 Otevřete **Learning** → **Parameter Learning**.
- 5 Zvolte dataset (cases) a metodu učení:
 - **Maximum Likelihood (MLE)** pro plná data (bez missing hodnot).
 - **Bayesian / Dirichlet** pro vyhlazení (bez nulových pravděpodobností).
- 6 Spustěte učení a uložte síť.

Kontrola: CPT nesmí zůstat uniformní (např. 0.333/0.333/0.333) pokud data nesou informaci.

Krok 4: Kontrola CPT tabulek v GeNIe

Otevřete CPT vybraných uzlů a ověřte logiku:

- $P(\text{Class} \mid \text{Animal})$: Robin $\rightarrow$ Bird, Monkey $\rightarrow$ Mammal, Turtle $\rightarrow$ Reptile.
- $P(\text{WarmBlooded} \mid \text{Class})$: Bird/Mammal $\rightarrow$ True, Reptile $\rightarrow$ False.
- $P(\text{BodyCovering} \mid \text{Class})$: Bird $\rightarrow$ Down, Mammal $\rightarrow$ Hair, Reptile $\rightarrow$ Scales.

Pozn.: při deterministických datech mohou vycházet hodnoty velmi blízko 0/1.

Krok 5: Inference v GeNIe (dotazy a evidence)

Zadejte evidence a vyhodnoťte dotaz.

Příklad 1: evidence Class = Bird

$$P(\text{WarmBlooded} = \text{True} \mid \text{Class} = \text{Bird})$$

Příklad 2: evidence BodyCovering = Hair, Environment = Land

$$P(\text{Animal} \mid \text{BodyCovering} = \text{Hair}, \text{Environment} = \text{Land})$$

Krok 6: Validace modelu na testovacích datech

Cíl: Ověřit kvalitu naučeného Bayesovského modelu na nových datech.

Vstup:

- Trénovací data: `Animals_train.txt`
- Testovací data: `Animals_test.txt`

Princip:

- Model je naučen pouze na trénovacích datech.
- Testovací data slouží pro nezávislé ověření.
- Pro každý testovací záznam predikujeme cílovou proměnnou.

Cílová proměnná:

`Animal`

Úloha: Porovnat predikovanou třídu se skutečnou hodnotou.

Krok 7: Postup validace v GeNIe

Postup:

- 1 Otevřete naučený model.
- 2 Načtěte testovací data:
 - Data → Cases
 - Vyberte soubor `Animals_test.txt`
- 3 Otevřete nástroj:

Validate

- 4 Vyberte:
 - Dataset: testovací data
 - Target node: `Animal`
- 5 Spusťte testování.

Výstup:

- Predikce pro každý záznam
- Matice záměn (Confusion Matrix)
- Přesnost modelu (Accuracy)

Krok 8: Vyhodnocení kvality modelu

Základní metrika: přesnost (Accuracy)

$$Accuracy = \frac{\text{počet správných predikcí}}{\text{celkový počet případů}}$$

Confusion Matrix:

- Řádky: skutečné třídy
- Sloupce: predikované třídy

Další metriky (volitelné):

- Precision
- Recall
- F1-score

Interpretace:

- Vysoká přesnost $\Rightarrow$ model dobře generalizuje
- Nízká přesnost $\Rightarrow$ problém v:
 - struktuře sítě,
 - kvalitě dat,
 - nedostatečném množství dat

Krok 9: Analýza chyb

Úkol: analyzujte nesprávné klasifikace

- 1 Identifikujte chybně klasifikované případy.
- 2 Zjistěte:
 - které třídy se zaměňují,
 - za jakých podmínek dochází k chybám.
- 3 Zamyslete se nad příčinami:
 - nedostatečné atributy,
 - špatná struktura sítě,
 - deterministická data vs. šum.

Cíl: Porozumět limitům Bayesovského modelu.