

Úvod do Bayesovských sítí a Bayesovské statistiky

Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Co je pravděpodobnost?

Intuitivní definice:

Pravděpodobnost vyjadřuje míru nejistoty výskytu náhodného jevu.

Klasická definice (Laplace):

Je-li experiment symetrický,

$$P(A) = \frac{\text{počet příznivých případů}}{\text{počet všech možných případů}}$$

Platí:

$$0 \leq P(A) \leq 1$$

$$P(\Omega) = 1$$

Příklad:

Hod kostkou.

$$P(\text{padne } 3) = \frac{1}{6}$$

$$P(\text{sudé číslo}) = \frac{3}{6} = 0.5$$

Pravděpodobnostní prostor: význam jednotlivých složek

Formální definice: Pravděpodobnostní prostor je trojice

$$(\Omega, \mathcal{F}, P).$$

- Ω (**výsledkový prostor, sample space**) – množina *všech* možných elementárních výsledků náhodného pokusu.
 - Každý prvek $\omega \in \Omega$ představuje jeden konkrétní výsledek (tzv. *elementární jev*).
 - Příklad (hod kostkou):

$$\Omega = \{1, 2, 3, 4, 5, 6\}.$$

- $\mathcal{F}$ (**systém jevů, σ -algebra**) – množina *všech jevů*, kterým umíme přiřadit pravděpodobnost.
 - **Jev** je podmnožina Ω : $A \subseteq \Omega$.
 - $\mathcal{F}$ typicky obsahuje minimálně:
 - prázdný jev $\emptyset$ (nenastane nic),
 - jistý jev Ω (nastane vždy),
 - Příklad (kostka): jev “padne sudé číslo”

$$A = \{2, 4, 6\} \subseteq \Omega.$$

- P (**pravděpodobnostní míra**) – pravidlo, které každému jevu $A \in \mathcal{F}$ přiřadí číslo $P(A) \in [0, 1]$.

Základní vlastnosti pravděpodobnosti

1. Nezápornost

$$P(A) \geq 0$$

2. Normalizace

$$P(\Omega) = 1$$

3. Aditivita pro disjunktní jevy

$$P(A \cup B) = P(A) + P(B) \quad \text{pokud } A \cap B = \emptyset$$

Obecný vztah:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Odečítáme průnik, abychom jej nepočítali dvakrát.

Praktický příklad – logická operace OR

Server může selhat:

- z důvodu HW (A)
- z důvodu SW (B)

$$P(A) = 0.1$$

$$P(B) = 0.2$$

$$P(A \cap B) = 0.05$$

$$P(A \cup B) =$$

$$0.1 + 0.2 - 0.05 = 0.25$$

Pravděpodobnost, že server selže z libovolného důvodu, je 25 %.

Definice:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Interpretace:

Pravděpodobnost jevu A za předpokladu, že nastal jev B.

Z rovnice plyne:

$$P(A \cap B) = P(A \mid B)P(B)$$

Tento vztah je klíčový pro Bayesovu větu.

Intuice podmíněné pravděpodobnosti

Podmínění znamená, že:

- zmenšujeme prostor Ω
- pracujeme pouze s případy, kde platí B

Nový normalizovaný prostor má velikost:

$$P(B)$$

V něm zjišťujeme podíl výskytu A.

Příklad – spam filtr: Necht':

$$P(\textit{Spam}) = 0.3$$

$$P(\textit{slovo} \textit{"FREE"} \mid \textit{Spam}) = 0.8$$

$$P(\textit{slovo} \textit{"FREE"} \mid \textit{Ham}) = 0.1$$

Otázka: Jaká je pravděpodobnost, že email je spam, pokud obsahuje slovo "FREE"?

Rozklad společné pravděpodobnosti tří jevů

Chceme vyjádřit společnou pravděpodobnost tří jevů:

$$P(A \cap B \cap C)$$

Pomocí podmíněné pravděpodobnosti platí:

$$P(A \cap B \cap C) = P(A \mid B, C) P(B \mid C) P(C).$$

Tento vztah se nazývá **řetězové pravidlo (chain rule)**.

Odvození vztahu krok za krokem

Začneme definicí podmíněné pravděpodobnosti:

$$P(A \cap B) = P(A | B)P(B).$$

Nyní aplikujeme tento vztah na jev $(A \cap B)$ podmíněný jevem C :

$$P(A \cap B \cap C) = P(A \cap B | C)P(C).$$

Ale opět použijeme definici:

$$P(A \cap B | C) = P(A | B, C) P(B | C).$$

Dosazením dostáváme:

$$P(A \cap B \cap C) = P(A | B, C) P(B | C) P(C).$$

Společnou pravděpodobnost tří jevů lze chápat jako postupné podmínění:

- Nejprve nastane C
- Poté nastane B za podmínky C
- Nakonec nastane A za podmínky B a C

Tedy pravděpodobnosti „řetězíme“:

společná pravděpodobnost = poslední podmíněná $\times$ předchozí podmíněná $\times$
základní pravděpodobnost.

Praktický příklad

Nechť:

- C = uživatel je připojen k síti
- B = proběhne autentizace
- A = přístup k databázi

Pak

$$P(A \cap B \cap C) = P(A \mid B, C) P(B \mid C) P(C).$$

Interpretace:

- Pravděpodobnost, že uživatel získá přístup,
- závisí na tom, že je připojen,
- a že úspěšně prošel autentizací.

Dvě základní statistické filozofie

Frekventistický přístup

- Parametr θ je pevná (neznámá) konstanta
- Pravděpodobnost = limitní relativní četnost
- Data jsou náhodná, parametr je fixní

Bayesovská statistika pracuje s distribucí parametru.

Základní struktura Bayesovského modelu: Bayesovský model obsahuje tři složky:

1 Apriorní rozdělení

$$P(\theta)$$

2 Věrohodnost (likelihood)

$$P(D \mid \theta)$$

3 Aposteriorní rozdělení

$$P(\theta \mid D)$$

Tyto veličiny propojuje Bayesova věta.

Bayesovský přístup

- Parametr θ je náhodná veličina
- Pravděpodobnost = míra nejistoty
- Aktualizujeme víru o parametru pomocí dat

Apriorní rozdělení (prior)

Definice: Apriorní rozdělení $P(\theta)$ vyjadřuje naši míru nejistoty o parametru θ před pozorováním dat D .

V bayesovském přístupu je parametr θ náhodná veličina s pravděpodobnostním rozdělením:

$$\theta \sim P(\theta)$$

Apriorní rozdělení kvantifikuje naši předchozí znalost, zkušenost nebo subjektivní víru.

Příklad (deštník a déšť): Necht'

$$\theta = P(\text{Děšť})$$

Interpretace: Pokud předpověď říká „možný déšť“, a naše apriorní víra je 0.5, máme racionální důvod vzít si deštník.

Na základě posledních 10 dnů máme:

Den	Děšť	Děštník
1	1	1
2	0	1
3	1	0
4	0	0
5	1	1
6	1	1
7	0	0
8	0	0
9	1	0
10	0	0

Součet deštivých dnů: 5 z 10

$$\hat{\theta}_{prior} = \frac{5}{10} = 0.5$$

Apriorní odhad pravděpodobnosti deště je tedy 0.5.

Bayesova věta (Děšť a deštník)

Události:

$$D = \{\text{Děšť}\}, \quad U = \{\text{Vzal(a) jsem si deštník}\}$$

Definice podmíněné pravděpodobnosti:

$$P(D | U) = \frac{P(D \cap U)}{P(U)}, \quad P(U | D) = \frac{P(D \cap U)}{P(D)}$$

Z druhé rovnice vyjádříme průnik:

$$P(D \cap U) = P(U | D) P(D)$$

Dosadíme do první rovnice:

$$P(D | U) = \frac{P(U | D) P(D)}{P(U)}$$

Bayesova věta (v našem příkladu):

$$P(\text{Děšť} | \text{Deštník}) = \frac{P(\text{Deštník} | \text{Děšť}) P(\text{Děšť})}{P(\text{Deštník})}$$

Bayesova věta (Děšť a deštník)

Odhad pravděpodobností z tabulky (10 dnů):

$$P(D) = \frac{5}{10} = 0.5, \quad P(U) = \frac{4}{10} = 0.4, \quad P(U | D) = \frac{3}{5} = 0.6$$

Výpočet:

$$P(D | U) = \frac{0.6 \cdot 0.5}{0.4} = 0.75$$

Interpretace: Pokud si člověk vzal deštník, pak podle těchto dat je pravděpodobnost deště 75 %.

Úplná disjunkttní množina událostí

Mějme úplnou a disjunkttní množinu hypotéz $H_1, H_2, \dots, H_n$, tak že:

$$\bigcup_{i=1}^n H_i = \Omega, \quad H_i \cap H_j = \emptyset, \quad i \neq j \quad \sum_{i=1}^n P(H_i) = 1 \quad (1)$$

Pak lze pravděpodobnost E vyjádřit pomocí podmíněných pravděpodobností:

$$P(E) = \sum_{i=1}^n P(H_i)P(E|H_i) \quad (2)$$

Toto je tzv. věta o úplné pravděpodobnosti.

Přechod k Bayesově větě

Z definice podmíněné pravděpodobnosti máme:

$$P(H_k|E) = \frac{P(H_k \cap E)}{P(E)} \quad (3)$$

Zároveň platí:

$$P(H_k \cap E) = P(H_k)P(E|H_k) \quad (4)$$

Dosaďme do (3):

$$P(H_k|E) = \frac{P(H_k)P(E|H_k)}{P(E)} \quad (5)$$

Dosadíme za $P(E)$ z věty o úplné pravděpodobnosti:

$$P(E) = \sum_{i=1}^n P(H_i)P(E|H_i) \quad (6)$$

Tím dostaneme Bayesovu formuli:

$$P(H_k|E) = \frac{P(H_k)P(E|H_k)}{\sum_{i=1}^n P(H_i)P(E|H_i)} \quad (7)$$

- Bayesova formule vyjadřuje, jak aktualizovat naši důvěru v platnost hypotézy H_k po pozorování E .
- Apriorní pravděpodobnosti $P(H_k)$ mohou být odhadnuty expertně.
- Bayesovský přístup je základem mnoha moderních metod učení a rozhodování.

Bayesova věta jako pomoc při rozhodování

Bayesovu větu lze použít v reálných situacích jako nástroj podpory rozhodování.

Příklad:

- Mladý muž se pokouší posoudit postoj ženy na základě jejího chování.
- Předpokládá 5 možných stavů (hypotéz):
 - H_1 : Zcela se nelíbí
 - H_2 : Nelíbí se
 - H_3 : Neutrální pocity
 - H_4 : Líbí se
 - H_5 : Zamilovanost na první pohled
- Apriorní pravděpodobnosti:

$$P(H) = [0,1, 0,15, 0,5, 0,2, 0,05]$$

Pravděpodobnosti pozorování při daném stavu ženy:

Pozorování	H_1	H_2	H_3	H_4	H_5
Kontakt pohledem	0,1	0,2	0,4	0,2	0,1
Úsměv	0,1	0,1	0,2	0,4	0,2
Požádala o pití	0,52	0,45	0,029	0,0009	0,0001
Dívá se na jiné muže	0,3	0,4	0,2	0,08	0,02
Krátké fráze	0,1	0,4	0,3	0,1	0,1
Toaleta + make-up	0,05	0,05	0,1	0,2	0,6

Výpočet pro první pozorování: kontakt pohledem

Použijeme Bayesovu větu pro každou hypotézu:

$$P(H_i|E) = \frac{P(H_i)P(E|H_i)}{\sum_{j=1}^n P(H_j)P(E|H_j)}$$

Vektory:

$$P(H) = [0,1, 0,15, 0,5, 0,2, 0,05]$$

$$P(E|H) = [0,1, 0,2, 0,4, 0,2, 0,1]$$

Součinnové členy:

$$P(H_i)P(E|H_i) = [0,01, 0,03, 0,20, 0,04, 0,005]$$

Normační člen:

$$\sum = 0,01 + 0,03 + 0,20 + 0,04 + 0,005 = 0,285$$

Výsledné posteriorní pravděpodobnosti

- $P(H_1|E) = \frac{0,01}{0,285} \approx 0,035$
- $P(H_2|E) = \frac{0,03}{0,285} \approx 0,105$
- $P(H_3|E) = \frac{0,20}{0,285} \approx 0,702$
- $P(H_4|E) = \frac{0,04}{0,285} \approx 0,140$
- $P(H_5|E) = \frac{0,005}{0,285} \approx 0,018$

Závěr: Nejpravděpodobnější je stav H_3 : neutrální pocity (70 %).

Tuto proceduru lze opakovat pro další pozorování (např. „úsměv“, „toaleta“...). Za předpokladu podmíněné nezávislosti pozorování konečná důvěra v hypotézu je dána vynásobením příslušných členů vektoru pro všechna pozorování.

Více pozorování – násobení věrohodností

Mějme jednu hypotézu H a několik pozorování $E_1, E_2, \dots, E_m$.

Za předpokladu **podmíněné nezávislosti** pozorování při dané hypotéze platí:

$$P(E_1, E_2, \dots, E_m \mid H) = \prod_{k=1}^m P(E_k \mid H)$$

Dosadíme do Bayesovy věty:

$$P(H \mid E_1, E_2, \dots, E_m) = \frac{P(H) \prod_{k=1}^m P(E_k \mid H)}{\sum_j P(H_j) \prod_{k=1}^m P(E_k \mid H_j)}$$

Tedy (až na normalizační konstantu):

$$P(H \mid E_1, \dots, E_m) \propto P(H) \prod_{k=1}^m P(E_k \mid H)$$

Interpretace:

Posteriorní důvěra v hypotézu je dána:

- apriorní pravděpodobností $P(H)$,
- násobením všech věrohodností jednotlivých pozorování.

Instalace softwaru GeNIe (BayesFusion)

GeNIe je grafické prostředí pro tvorbu a analýzu Bayesovských sítí využívající výpočetní jádro SMILE.

1. Stažení softwaru

Oficiální stránka: <https://www.bayesfusion.com/downloads/>

- Vybrat verzi **GeNIe Academic**
- Registrace akademickým e-mailem (univerzitní doména)

2. Windows (doporučeno)

- Stáhnout: **GeNIe x64 Installer (.exe)**
- Spustit instalátor

3. macOS

- GeNIe nemá nativní verzi pro macOS
- Použít prostředí **Wine** nebo virtuální stroj (např. Windows VM)

4. Linux

- Spustit pomocí **Wine**
- Alternativně použít virtuální stroj s Windows

Poznámka: Nestahovat software „GENIE Programming Editor“ (jedná se o jiný produkt určený pro PLC programování).

Bayesova aktualizace v Pythonu: vstupní data

Cíl: implementovat aktualizaci $P(H | E)$ (stejně jako v GeNIe) pro diskrétní hypotézy $H_1, \dots, H_5$ a pozorování E .

1) Hypotézy a apriorní rozdělení: $P(H)$

2) Věrohodnosti (likelihood): pro každé pozorování E_k zadáme vektor $P(E_k | H_i)$.

```
import numpy as np
import pandas as pd

hypotheses = [
    'H1: Totally dislikes', 'H2: Dislikes',
    'H3: Neutral', 'H4: Likes', 'H5: In love'
]
priors = np.array([0.1, 0.15, 0.5, 0.2, 0.05])

observations = {
    'Eye contact': [0.1, 0.2, 0.4, 0.2, 0.1],
    'Smile': [0.1, 0.1, 0.2, 0.4, 0.2],
    'Asked for drink': [0.52, 0.45, 0.029, 0.0009, 0.0001],
    'Looks at other men': [0.3, 0.4, 0.2, 0.08, 0.02],
    'Short phrases': [0.1, 0.4, 0.3, 0.1, 0.1],
    'Make-up in bathroom': [0.05, 0.05, 0.1, 0.2, 0.6]
}
```

Bayesova aktualizace: funkce bayes_update

Pro jedno pozorování E platí Bayesova formule:

$$P(H_i | E) = \frac{P(H_i) P(E | H_i)}{\sum_j P(H_j) P(E | H_j)}$$

V kódu:

- joint odpovídá $P(H_i)P(E | H_i)$ (nenormalizované hodnoty),
- normalization je $P(E)$ (normalizační konstanta),
- posterior je výsledné $P(H | E)$.

```
def bayes_update(prior, likelihood):  
    joint = prior * likelihood  
    normalization = np.sum(joint)  
    posterior = joint / normalization  
    return posterior, normalization
```

Aktualizace pro jednotlivá pozorování (odděleně)

Pro každé pozorování E_k počítáme zvlášť posterior:

$$P(H \mid E_k)$$

```
likelihood_1 = np.array(observations['Eye contact'])
posterior_1, norm_1 = bayes_update(priors, likelihood_1)

likelihood_2 = np.array(observations['Smile'])
posterior_2, norm_2 = bayes_update(priors, likelihood_2)

likelihood_3 = np.array(observations['Asked for drink'])
posterior_3, norm_3 = bayes_update(priors, likelihood_3)
```

Poznámka: Zde vždy používáme stejné priors; ostatní pozorování se do výpočtu nezahrnují (záměrně analyzujeme vliv jednoho evidence).

Výsledky v tabulce (Pandas DataFrame)

Pro přehlednost zobrazíme prior a posterior pro každé samostatné pozorování.

```
results_df = pd.DataFrame({
    'Hypothesis': hypotheses,
    'Prior P(H)': priors,
    'Posterior given Eye contact': posterior_1,
    'Posterior given Smile': posterior_2,
    'Posterior given Asked for drink': posterior_3,
    'Posterior given Looks at other men': posterior_4,
    'Posterior given Short phrases': posterior_5,
    'Posterior given Make-up in bathroom': posterior_6
})
print(results_df.round(3))
```

Kombinace více evidence (naivní Bayes)

Za předpokladu **podmíněné nezávislosti** pozorování při dané hypotéze:

$$P(H \mid E_1, \dots, E_m) \propto P(H) \prod_{k=1}^m P(E_k \mid H)$$

Proto můžeme pro každý H_i **násobit** příslušné likelihood:

$$\prod_{k=1}^m P(E_k \mid H_i)$$

```
total_likelihood = (  
    np.array(observations['Eye contact']) *  
    np.array(observations['Smile']) *  
    np.array(observations['Asked for drink']) *  
    np.array(observations['Looks at other men']) *  
    np.array(observations['Short phrases']) *  
    np.array(observations['Make-up in bathroom'])  
)  
  
posterior_all, norm_all = bayes_update(priors, total_likelihood)
```

Souhrnná tabulka: jednotlivě vs. všechna evidence

Srovnání:

- **given E_k :** posterior jen pro jedno pozorování,
- **all evidences:** posterior pro kombinaci všech pozorování (naivní Bayes).

```
results_df = pd.DataFrame({
    'Hypothesis': hypotheses,
    'Prior P(H)': priors,
    'Posterior given Eye contact': posterior_1,
    'Posterior given Smile': posterior_2,
    'Posterior given Asked for drink': posterior_3,
    'Posterior given Looks at other men': posterior_4,
    'Posterior given Short phrases': posterior_5,
    'Posterior given Make-up in bathroom': posterior_6,
    'Posterior all evidences': posterior_all
})
print(results_df.round(3))
```