

Porovnání klasických a Bayesovských statistických metod

Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

sergii.babichev@ujep.cz

Cíl praktické úlohy: porovnání přístupů

Hlavní cíl: porovnat klasické statistické modely a Bayesovský přístup na datové sadě **Student Performance**.

Část 1 – Bayesovská síť (GeNIe):

- návrh struktury (DAG),
- definice stavů (diskretizace),
- učení parametrů (CPT),
- inference a interpretace.

Část 2 – Klasický model (Python nebo R):

- volba modelu (např. Random Forest),
- trénování modelu na stejných datech,
- vyhodnocení kvality modelu.

Cíl porovnání:

- interpretovatelnost,
- přesnost predikce,
- práce s nejistotou.

Pro korektní porovnání musí oba přístupy pracovat se stejnými daty.

Bayesovská síť (GeNIe):

- vstup: diskretizovaná data (kategorie),
- modeluje pravděpodobnostní závislosti.

Klasické modely:

- vstup:
 - buď' původní numerická data,
 - nebo stejné diskretizované varianty (volitelné).
- cílem je predikce PerformanceIndex.

Klasické statistické modely (zadání)

Úkol: vytvořit alespoň jeden klasický model.

Možné modely:

- lineární regrese,
- rozhodovací strom,
- Random Forest,
- jiný vhodný model.

Požadavky:

- rozdělení dat na train/test,
- trénování modelu,
- výpočet metrik (např. MSE, RMSE, Accuracy).

Výstup:

- predikce cílové proměnné,
- kvantitativní hodnocení modelu.

Kritéria porovnání modelů

Studenti musí porovnat oba přístupy podle následujících kritérií:

1. Přesnost:

- klasické modely: MSE, RMSE, Accuracy,
- BN: kvalita inference (pravděpodobnosti).

2. Interpretovatelnost:

- klasické modely: koeficienty, feature importance,
- BN: struktura grafu a CPT.

3. Práce s nejistotou:

- klasické modely: bodová predikce,
- BN: pravděpodobnostní rozdělení.

4. Flexibilita:

- BN: diagnostická inference,
- klasické modely: predikční výkon.

Datová sada a proměnné (cases)

Vstupní data: tabulka případů (cases), každý řádek je jedna pozorovaná situace.

Proměnné:

- **Hours Studied** (1–9) – počet hodin studia (diskretizovat).
- **Previous Scores** (40–99) – předchozí skóre (diskretizovat).
- **Sleep Hours** (4–9) – délka spánku (diskretizovat).
- **Sample Question Papers Practiced** (0–9) – počet procvičených testů (diskretizovat).
- **Extracurricular Activities** $\in \{\text{Yes, No}\}$ – mimoškolní aktivity (ponechat).
- **Performance Index** (10–100) – výkonnost (cílová proměnná; diskretizovat).

Úloha: z dat naučit tabulky podmíněných pravděpodobností (CPT) a provést inference.

Diskretizace numerických proměnných (stavů)

BN v GeNIe pracuje se **stavy** (kategoriemi). Numerické atributy je nutné převést na intervaly.

Doporučené intervaly (příklad):

- Hours Studied: {Low: 1–3, Medium: 4–6, High: 7–9}
- Previous Scores: {Low: 40–60, Medium: 61–80, High: 81–99}
- Sleep Hours: {Low: 4–5, Normal: 6–7, High: 8–9}
- Sample Papers: {Low: 0–3, Medium: 4–6, High: 7–9}
- Performance Index: {Low: 10–40, Medium: 41–70, High: 71–100}

Pozor: textové hodnoty musí být konzistentní (např. pouze Yes/No bez variant typu YES).

Diskretizace numerických proměnných (stavů)

```
import pandas as pd

df = pd.read_csv("Student_Performance.csv", sep=";")

df["Hours_cat"] = pd.cut(
    df["Hours Studied"],
    bins=[0,3,6,9],
    labels=["Low", "Medium", "High"]
)
df["Score_cat"] = pd.cut(
    df["Previous Scores"],
    bins=[39,60,80,100],
    labels=["Low", "Medium", "High"]
)
.....

df_bn = df[[
    "Hours_cat",
    "Score_cat",
    "Extracurricular Activities",
    "Sleep_cat",
    "Practice_cat",
    "Performance_cat"
]]

df_bn.to_csv("student_bn.csv", index=False)
```


Návrh struktury BN (DAG) – doporučený model

Navrhňte směrovaný acyklický graf (DAG) odpovídající doménové logice.

Doporučená struktura (Variant A: s latentní proměnnou):

- StudyDiscipline $\rightarrow$ HoursStudied
- StudyDiscipline $\rightarrow$ PracticePapers
- StudyDiscipline $\rightarrow$ SleepHours
- Extracurricular $\rightarrow$ HoursStudied
- Extracurricular $\rightarrow$ SleepHours
- PreviousScores $\rightarrow$ PerformanceIndex
- HoursStudied $\rightarrow$ PerformanceIndex
- PracticePapers $\rightarrow$ PerformanceIndex
- SleepHours $\rightarrow$ PerformanceIndex
- (Volitelné) Extracurricular $\rightarrow$ PerformanceIndex

Kontrola: graf nesmí obsahovat cyklus (např. $A \rightarrow B \rightarrow A$).

Vytvoření BN v GeNIe (uzly, stavy, hrany)

Postup v GeNIe:

- 1 Vytvořte nový projekt a vložte uzly pro všechny proměnné.
- 2 U každého uzlu nastavte **Type = Chance**.
- 3 Nastavte **States** přesně podle diskretizace (Low/Medium/High) a dle domény (Yes/No).
- 4 Přidejte hrany dle navrženého DAG.

Pozor na názvy: názvy uzlů musí přesně odpovídat názvům sloupců v CSV (ideálně bez mezer; doporučeno přejmenovat sloupce při exportu z Pythonu).

Kontrola rodičů: ověřte množinu rodičů $Pa(X)$ pro klíčové uzly (zejména PerformanceIndex).

Import dat (Cases) do GeNIe a učení parametrů (CPT)

Import tabulky případů:

- 1 Otevřete **Data/Cases**.
- 2 Načtěte `student_bn.csv` a ověřte mapování sloupců na uzly (1:1).
- 3 Otevřete **Learning** → **Parameter Learning**.
- 4 Zvolte metodu učení:
 - **Maximum Likelihood (MLE)** pro plná data bez missing hodnot.
 - **Bayesian/Dirichlet** pro vyhlazení (doporučeno kvůli nulovým pravděpodobnostem).
- 5 Spusťte učení a uložte síť (`.xds1`).

Kontrola: CPT by neměly zůstat uniformní, pokud data nesou informaci.

Kontrola CPT a interpretace (GeNIe)

Otevřete CPT vybraných uzlů a ověřte logiku závislostí:

- $P(\text{PerformanceIndex} \mid \text{HoursStudied})$: vyšší studium $\Rightarrow$ vyšší pravděpodobnost High.
- $P(\text{PerformanceIndex} \mid \text{PreviousScores})$: vyšší skóre $\Rightarrow$ vyšší pravděpodobnost High.
- $P(\text{HoursStudied} \mid \text{Extracurricular})$: u některých dat lze pozorovat posun rozdělení.

Pozn.: silné statistické vazby neznamenaají kauzalitu (diskuse: korelace vs. příčina).

Inference v GeNIe (dotazy a evidence)

Zadejte evidence a vyhodnoťte dotazy (uložte screenshoty výsledných rozdělání).

Příklad 1: evidence HoursStudied = High, SleepHours = High

Dotaz: $P(\text{PerformanceIndex})$

Příklad 2: evidence PreviousScores = Low, PracticePapers = High

Dotaz: $P(\text{PerformanceIndex})$

Příklad 3: evidence PerformanceIndex = High

Dotaz: $P(\text{HoursStudied})$, $P(\text{SleepHours})$ (diagnostická inference)

Doporučení: porovnejte výsledky pro Extracurricular = Yes vs. No (stejně ostatní evidence).

Zadání úlohy: Bayesovská síť pro hodnocení úvěrové spolehlivosti

Cílem úlohy je vytvořit **Bayesovskou síť**, která umožňuje odhadnout **úvěrovou spolehlivost jednotlivce** na základě finančních a osobních charakteristik.

Model vychází z několika proměnných popisujících:

- finanční situaci jednotlivce,
- pracovní stabilitu,
- historii splácení závazků,
- očekávaný budoucí finanční vývoj.

Výsledkem modelu je odhad pravděpodobnosti stavu uzlu

Credit Worthiness

který reprezentuje schopnost osoby splácet úvěr.

Vysvětlení uzlů Bayesovské sítě

Debit – výše současného dluhu jednotlivce.

Income – roční nebo měsíční příjem osoby.

Assets – majetek nebo finanční rezervy.

Ratio of Debts to Income – poměr dluhů k příjmu, který charakterizuje finanční zatížení osoby.

Payment History – historie splácení předchozích úvěrů.

Work History – stabilita pracovního poměru.

Reliability – celková spolehlivost klienta na základě pracovních a platebních údajů.

Age – věková kategorie jednotlivce.

Profession – typ zaměstnání nebo profesní skupina.

Worth – celkové finanční postavení osoby, které vychází z příjmu a majetku.

Future Income – očekávaný budoucí příjem, závislý na profesi a současné finanční situaci.

Credit Worthiness – cílový uzel Bayesovské sítě, reprezentuje pravděpodobnost, že osoba bude schopna splácet úvěr.

Model vypočítá pravděpodobnost stavů:

Positive / Negative

Doporučená struktura Bayesovské sítě

Finanční vztahy

- Income $\rightarrow$ RatioOfDebtsToIncome
- Debit $\rightarrow$ RatioOfDebtsToIncome
- Income $\rightarrow$ Worth
- Assets $\rightarrow$ Worth

Spolehlivost klienta

- PaymentHistory $\rightarrow$ Reliability
- WorkHistory $\rightarrow$ Reliability

Budoucí finanční situace

- Profession $\rightarrow$ FutureIncome
- Worth $\rightarrow$ FutureIncome

Konečné rozhodnutí

- Reliability $\rightarrow$ CreditWorthiness
- Age $\rightarrow$ CreditWorthiness
- FutureIncome $\rightarrow$ CreditWorthiness

Cílem je vytvořit a otestovat Bayesovskou síť pro hodnocení úvěrové spolehlivosti osoby.

- ❶ Definujte uzly Bayesovské sítě podle popisu proměnných.
- ❷ Vytvořte strukturu sítě (DAG) podle doporučených závislostí mezi proměnnými.
- ❸ Implementujte model v prostředí **GeNIe Academic**:
 - vytvořte uzly a jejich stavy,
 - definujte závislosti mezi uzly,
 - nastavte tabulky pravděpodobností (CPT).
- ❹ Implementujte stejný model v prostředí **Python**.
- ❺ Proveďte pravděpodobnostní inferenci pro různé scénáře klientů.

Po implementaci modelu by měla Bayesovská síť umožnit:

- odhadnout pravděpodobnost stavu uzlu **CreditWorthiness** (Positive / Negative),
- analyzovat vliv jednotlivých faktorů na schopnost splácet úvěr,
- provádět scénářovou analýzu změnou evidence (např. změna příjmu nebo pracovní stability),
- interpretovat vztahy mezi finanční situací, spolehlivostí klienta a očekávaným budoucím příjmem.

Výsledkem je pravděpodobnostní model podporující **rozhodování o poskytnutí úvěru**.

Rozšíření úlohy: klasický model

Kromě Bayesovské sítě implementujte také klasický model:

Logistická regrese

Cíl:

- predikovat CreditWorthiness (Positive / Negative),
- porovnat výsledky s Bayesovskou sítí.

Pozn.: Data jsou již diskretizovaná (hodnoty 0–3), je možné je použít přímo jako vstup modelu.

Příprava dat pro logistickou regresi

Vstupní proměnné:

- PaymentHistory
- WorkHistory
- Reliability
- Debit
- Income
- RatioDeblnc
- Assets
- Worth
- Profession
- FutureIncome
- Age

Cílová proměnná:

- CreditWorthiness (0 / 1)

Krok:

- rozdělíte data na trénovací a testovací množinu (např. 70/30).

Logistická regrese: model

Model:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (1)$$

Interpretace:

- model odhaduje pravděpodobnost,
- koeficienty β_i určují vliv jednotlivých proměnných.

Výstup:

- pravděpodobnost třídy,
- finální klasifikace (0 / 1).

Implementace logistické regrese (zadání)

Postup:

- 1 Načtěte data (`Credit.txt`).
- 2 Oddělte vstupní proměnné X a cílovou proměnnou Y .
- 3 Rozdělte data na train/test.
- 4 Natrénujte model logistické regrese.
- 5 Vypočítejte predikce na testovacích datech.

Metriky:

- Accuracy
- Precision
- Recall
- F1-score