


ČAS ULTIMATE V2

Dekompozice


- Dekompozice = rozbor časové řady na trend, sezónnost a náhodnou složku
- Časová řada se vždy řídí jedním z těchto dvou modelů:
 - Aditivní model

- $Y_t = Tr_t + Ct + St + \varepsilon_t$
- Y_t = Časová řada
- Tr_t = Trend
- Ct = Cyklická složka - nejde odhadnout tak se odhaduje s trendem
- St = Sezónnost
- ε_t = Náhodný šum
- Kdy aditivní:
 - Sezónní výkyvy mají přibližně stejnou velikost v průběhu celého období.
 - Sezónní výkyvy se nezvětšují s trendem



- Multiplikativní model

- $Y_t = Tr_t * Ct * St * \varepsilon_t$
- Kdy multiplikativní:
 - Sezónní výkyvy se zvětšují s trendem



Odhad trendu

- Odhad trendu je nejdůležitější pro dekompozici řady
- Poté co získám trend mohu snadno získat sezónnost a náhodný šum
- Jak získám trend:
 - Vyhlazením řady
 - Musím dávat pozor na sezónnost! (klouzavý průměr s oknem o velikosti sezóny)

Klouzavý průměr

- Metoda pro vyhlazení časové řady a získání trendu
- Získá trend tím, že během vyhlazení “odstraní” náhodnou složku
- Pokud není trend lineární jedním předpisem po celé ose (jinak by stačila lineární regrese :D)
- Počítá s přibližně lineárním, ne moc rychle se měnícím trendem
- 2 parametry: délka a řád
 - Délka:
 - počet pozorování, která se zahrnou do výpočtu průměru
 - Měla by být o velikosti jedné sezóny (pokud je přítomna sezónnost v datech)
 - větší délka = hladší křivka
 - Řád:
 - typ průměru který se použije
 - Hlavně: jednoduchý klouzavý průměr a vážený klouzavý průměr (větší váha novějším pozorováním)
 - **V praxi se jiný než lineární řád nepoužívá**

Exponenciální vyrovňávání

- Jako klouzavý průměr, ale lépe reaguje na určité situace (záleží na typu)
- Narozdíl od metody klouzavých prům. nepočítá hodnotu z obou stran, ale jen z minulosti
- Počítá se všemi předchozími hodnotami, jejich váha exponenciálně klesá čím dál od přítomnosti jsou
- Lépe reaguje na rychlé změny trendů
- **Jednoduché exponenciální vyrovňávání:**
 - konstantní úroveň, bez trendu a bez sezónnosti.
 - Využít jen když mi jde o to vyhladit data (například než použiju ARIMU)
- **Dvojitě exponenciální vyrovňávání:**
 - úroveň + lineární trend, bez sezónnosti.
 - Vyhladí a získá trend
- **Trojité exponenciální vyrovňávání (Holt-Winters metoda):**
 - úroveň + trend + sezónnost
 - Vyhladí a získá trend

Sezónnost

- Sezónnost se získá tím, že se získá a odstraní trend z řady, pak se zjistí co se opakuje = sezónnost. Co zbyde potom je náhodná složka.
- Například - průměr všech únorů, lednů, ... -> sezónní složka

Modelování (předpovídání) řady

Box-Jenkins metodologie

- Systematický přístup pro modelování časových řad (předpovídání, dekompozici, vyhlazení, odstranění šumu, ...)
- **Stacionarita** = data nemají trend
- **4 kroky Box-Jenkins metodologie:**
 1. Identifikace modelu
 - Diagnostika dat: Je časová řada stacionární?
 - Zvolí se vhodný typ ARIMA modelu: parametry (p , d , q)
 2. Odhad parametrů
 - Statistické metody (např. maximum likelihood) pro určení parametrů modelu.
 3. Diagnostika modelu
 - Testování zbytků (reziduí) modelu – měly by být náhodné.
 4. Predikce a validace
 - Použití modelu na budoucí predikce a porovnání s reálnými daty.
- ACF
 - Autokorelační funkce
 - Měří závislost mezi aktuální hodnotou a jejími předchozími hodnotami (lagy).
 - Ukazuje, jak silně jsou hodnoty v čase navzájem korelované.
 - Graf:
 - Sloupce (peaks) představují korelaci s hodnotami v určitém zpoždění (lagu).
 - Vysoký sloupec u určitého lagu znamená, že existuje silná závislost mezi hodnotami oddělenými tímto zpožděním.
 - Intervaly spolehlivosti (modré čáry): pokud sloupec přesahuje → významná autokorelace.
 - ACF pomáhá určit vhodnou hodnotu q (řád MA složky).
 - V ARIMA modelu tím zjišťuji, kolik minulých chyb ovlivňuje aktuální hodnotu.
- PACF
 - Parciální autokorelační funkce
 - Měří přímou (čistou) závislost mezi aktuální hodnotou a jejími předchozími lagy, při odfiltrování vlivu mezilehlých lagů.
 - Významný sloupec na lag k → silná přímá závislost s hodnotou před k kroky.
 - PACF pomáhá určit vhodnou hodnotu p (řád AR složky).
 - Určuje, kolik předchozích hodnot má přímý vliv na aktuální hodnotu.

- **AR model:**
 - AutoRegrese
 - Předpověď budoucích hodnot
 - Predikce na základě minulých hodnot
 - Objem paměti = řád modelu (p)
 - Čím vyšší p , tím víc minulých hodnot ovlivňuje současnost
 - Určení p (řádu) pomocí **PACF** (Partial Autocorrelation Function)
 - Předpoklady:
 - Stacionarita
 - Lineární závislost na předchozích hodnotách
- **MA model:**
 - Klouzavý průměr
 - Vyhlazení řady
 - Vyhlazuje šum pomocí chyb z minulosti
 - Kolik minulých chyb ovlivňuje současnost = řád modelu (q)
 - Určení q pomocí **ACF** (Autocorrelation Function)
 - Předpoklady:
 - Stacionarita
 - Bílý šum chyb (náhodná rezidua - testy)
 - Žádná dlouhodobá paměť
- **ARMA model:**
 - Kombinace AR a MA
 - Pro stacionární řady
 - Předpoklady:
 - Stacionarita
 - Bez trendu
 - Bez sezónnosti
- **ARIMA model:**
 - ARMA + integrování
 - Pro nestacionární řady
 - Rozšíření ARMA na nestacionární řady (tj. s trendem)
 - I = Integrace
 - Udělám d -násobné diferencování
 - Používá se k odstranění trendu z časové řady
 - " d " je počet diferencování
 - Diference = v řadě odečte předchozí hodnotu od momentální, udělá pro celou řadu, to odstraní trend
 - Po d -násobném diferencování je řada stacionární
 - Parametry(p, d, q):
 - p = autoregresní část
 - d = počet diferencování, které odstraní trend
 - q = klouzavý průměr
 - Rovnice se vztahuje ke změnám dat, ne přímo k hodnotám:
 - Nejprve vytvořím diferenci (např. rozdíl mezi aktuální a předchozí hodnotou)
 - Pak modeluji vzniklou (stacionární) řadu pomocí ARMA
 - Předpoklady:

- Nestacionární data (stanou se stacionární po diferencování,,, můžou mít trend)
 - Bez sezónnosti
- **ARIMAX** model:
 - ARIMA + sezónnost
 - Sezónnost se spočítá zvlášť pomocí externích regresorů získaných převážně fourierovou transformací a přidá se k ARIMA
- **SARIMA** model:
 - ARIMA + sezónnost
 - Sezónnost se modeluje uvnitř modelu pomocí sezónní diferenciace a parametrů
 - Narozdíl od ARIMAX nevyužívá externí regresory
 - Vhodné, když je sezónnost pravidelná a výrazná přímo v řadě
 - Předpoklady: stejné jako ARIMA + sezónnost v datech
- **VAR model (Vector Autoregression)**
 - Rozšíření AR(p) na vícero vzájemně se ovlivňujících časových řad
 - Každá proměnná závisí na svých i na zpožděných hodnotách všech ostatních proměnných
 - Parametry (p, k):
 - p = počet lagů (volí se podle AIC/BIC/HQ)
 - k = počet řad ve vektoru (např. 2: prodeje + kampaně)
 -
 - **Předpoklady:**
 - Všechny řady stacionární (případně dříve diferencovat)
 - Zbytky (rezidua) → bílý šum (žádná autokorelace, homoskedasticita, ideálně normální)
 - Stabilita (kořeny charakteristického polynomu $|\text{modul}| < 1$)